



МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(национальный исследовательский университет)»

Институт (Филиал) № 8 «Компьютерные науки и прикладная математика» Кафедра 806

Группа М8О-408Б-22 Направление подготовки 01.03.02 «Прикладная математика и информатика»

Профиль Информатика

Квалификация: бакалавр

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА БАКАЛАВРА

На тему: Распознавание визуальных признаков детских рисунков, ассоциированных с психологическими характеристиками ребёнка, нейросетевыми методами

Автор ВКРБ: Шелаев Серафим Ильич ()

Руководитель: Судаков Владимир Анатольевич ()

Консультант: — ()

Консультант: — ()

Рецензент: — ()

К защите допустить

Заведующий кафедрой № 806 Крылов Сергей Сергеевич ()

____ мая 2026 года

РЕФЕРАТ

Выпускная квалификационная работа бакалавра состоит из 49 страниц, 11 рисунков, 5 таблиц, 22 использованных источников, 2 приложений.

ДЕТСКИЕ РИСУНКИ, ПСИХОЛОГИЧЕСКАЯ ДИАГНОСТИКА, КЛАССИФИКАЦИЯ ИЗОБРАЖЕНИЙ, СВЁРТОЧНЫЕ НЕЙРОННЫЕ СЕТИ, MULTI-TASK LEARNING, ОБРАБОТКА ИЗОБРАЖЕНИЙ, КОМПЬЮТЕРНОЕ ЗРЕНИЕ, ТЕСТ ВЕНГЕРА, ПСИХОЛОГИЧЕСКИЙ ПОРТРЕТ

Объектом разработки в данной работе является программный комплекс автоматического анализа детских рисунков человека для оценки психологических характеристик ребёнка.

Цель работы — разработать нейросетевую систему распознавания визуальных признаков детских рисунков и их сопоставления с психологическими чертами на основе методики А. Л. Венгера.

Основное содержание работы состояло в проектировании собственной двухпоточной свёрточной нейронной сети, разработке алгоритма предобработки изображений на основе классических операций обработки изображений, обучении модели на 117 признаках в режиме multi-task и реализации модуля генерации текстового психологического портрета. Для удобства практического использования разработанные модули объединены в микросервисный веб-сервис с REST API и веб-интерфейсом.

Основным результатом работы является программный комплекс на языке Python с использованием библиотек PyTorch и OpenCV, оформленный в виде набора Docker-контейнеров.

Данные результаты разработки предназначены для использования специалистами в области детской психологии в качестве вспомогательного инструмента предварительного анализа, а также в исследовательских целях для анализа больших объёмов рисуночных тестов.

Внедрение разработки позволяет автоматизировать рутинную часть обработки рисуночных тестов, что снижает нагрузку на специалиста и повышает воспроизводимость результатов.

СОДЕРЖАНИЕ

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ	5
ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ	6
ВВЕДЕНИЕ	7
1 ПРЕДМЕТНАЯ ОБЛАСТЬ И ПОСТАНОВКА ЗАДАЧИ	10
1.1 Рисуночные тесты как инструмент психологической диагностики	10
1.2 Список психологических черт и канонические признаки рисунка	10
1.3 Современные подходы к классификации изображений	10
1.4 Особенности задачи и подход к её решению	11
1.5 Постановка задачи	12
2 РАЗРАБОТКА ПРОГРАММНОГО КОМПЛЕКСА	14
2.1 Общая архитектура решения	14
2.2 Описание датасета и его подготовка	15
2.3 Модуль предобработки изображений	16
2.4 Архитектура нейросетевой модели	17
2.5 Функции потерь и стратегия обучения	20
2.6 Словарь интерпретаций признаков	22
2.7 Генератор текстового психологического портрета	23
2.8 Микросервисная архитектура веб-сервиса	24
2.9 Технологический стек	27
2.10 Описание сервисов	27
2.11 Хранение данных	29
2.12 Контейнеризация и развёртывание	29
2.13 Поток данных при анализе одного рисунка	30
3 ЭКСПЕРИМЕНТАЛЬНОЕ ИССЛЕДОВАНИЕ	32
3.1 Условия проведения экспериментов	32
3.2 Метрики качества	32
3.3 Результаты на тестовой выборке	33
3.4 Анализ распределения метрик по признакам	35
3.5 Демонстрация работы программного комплекса	36
3.6 Анализ временных характеристик	37
3.7 Тестирование веб-сервиса	38
3.8 Сфера применения и ограничения	39
ЗАКЛЮЧЕНИЕ	42

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	45
ПРИЛОЖЕНИЕ А Исходный код	48
ПРИЛОЖЕНИЕ Б Архитектура нейросетевой модели	49

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

В настоящей выпускной квалификационной работе бакалавра применяют следующие термины с соответствующими определениями:

Рисуночный тест — проективная психодиагностическая методика, основанная на интерпретации создаваемого испытуемым рисунка

Multi-task learning — парадигма обучения, в которой одна модель одновременно решает несколько связанных задач, используя общее представление признаков

F1-мера — гармоническое среднее точности (precision) и полноты (recall) бинарного или мультиклассового классификатора

Ограничивающий прямоугольник — прямоугольная область изображения, в которую заключён обнаруженный объект; описывается координатами левого верхнего и правого нижнего углов

Адаптивная бинаризация — метод бинаризации изображения, в котором порог вычисляется индивидуально для каждой точки на основе локальной окрестности

Морфологические операции — базовые операции обработки бинарных изображений: эрозия, дилатация, замыкание (closing), размыкание (opening), основанные на структурирующем элементе

Выделение связных компонент — метод обработки бинарного изображения, при котором смежные единичные пиксели группируются в связные области; для каждой области вычисляются её координаты, размеры и площадь

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ

В настоящей выпускной квалификационной работе бакалавра применяют следующие сокращения и обозначения:

СНС — свёрточная нейронная сеть

МО — машинное обучение

API — программный интерфейс приложения (англ. Application Programming Interface)

REST — Representational State Transfer — архитектурный стиль построения веб-сервисов

HTTP — Hypertext Transfer Protocol — протокол передачи гипертекста

JSON — JavaScript Object Notation — текстовый формат обмена данными

СУБД — система управления базами данных

UUID — Universally Unique Identifier — универсально-уникальный идентификатор

ASGI — Asynchronous Server Gateway Interface — интерфейс асинхронного веб-сервера для Python

ТТА — Test-Time Augmentation — усреднение предсказаний по нескольким аугментированным версиям одного изображения

CLAHE — Contrast Limited Adaptive Histogram Equalization — адаптивное локальное выравнивание гистограммы с ограничением контраста

MLP — Multi-Layer Perceptron — многослойный перцептрон

GPU — Graphics Processing Unit — графический процессор

CV — Computer Vision — компьютерное зрение

ВВЕДЕНИЕ

Актуальность темы данной работы связана с растущей нагрузкой на детских психологов в образовательных учреждениях и медицинских центрах. Рисуночные тесты — одна из наиболее распространённых проективных методик, применяемых для предварительного скрининга психологических состояний детей дошкольного и младшего школьного возраста. Среди них особое место занимает тест «Рисунок человека», методология интерпретации которого детально разработана А. Л. Венгером. Однако ручная обработка рисунка специалистом занимает значительное время и подвержена субъективным факторам. Автоматизация хотя бы части этого процесса с помощью методов машинного обучения позволяет масштабировать применение методики и обеспечить воспроизводимость результатов.

Современные нейронные сети успешно применяются для широкого спектра задач классификации изображений. Однако специфика детских рисунков — бледные карандашные штрихи, схематичность, разнообразие стилей, разная плотность заполнения листа — ставит ряд особых задач: точная локализация фигуры на странице, обработка изображений с низким контрастом, корректное распознавание сильно несбалансированных категорий признаков.

Помимо технической задачи распознавания признаков, существует не менее важная задача доменной интерпретации: нейросеть выдаёт техническую характеристику рисунка, например: «размер крупный», «нажим сильный», «отсутствует шея» — но конечному пользователю необходимо получить психологически осмысленный текст, обобщающий совокупность признаков в характеристику ребёнка.

Цель работы — разработать нейросетевую систему распознавания визуальных признаков детских рисунков и их сопоставления с психологическими чертами на основе методики А. Л. Венгера. Для достижения поставленной цели в работе были решены следующие задачи:

- проведён анализ предметной области рисуночных тестов и существующих подходов к автоматизации их интерпретации;
- разработан алгоритм предобработки изображений, реализующий локализацию фигуры человека на листе на основе классических операций обработки изображений;

- спроектирована и обучена собственная нейронная сеть для одновременной классификации признаков рисунка;
- составлен словарь интерпретаций, сопоставляющий технические признаки рисунка с каноническими психологическими чертами по А. Л. Венгеру;
- реализован модуль генерации текстового психологического портрета на основе предсказаний модели;
- проведено экспериментальное исследование качества модели на тестовой выборке;
- для удобства практического использования разработанные модули объединены в микросервисный веб-сервис, обеспечивающий доступ к функциональности системы через браузер.

Для разработки системы необходимо изучить инструменты и методы, решающие поставленные задачи. Работа основывается на следующих библиотеках, технологиях и алгоритмах:

- Python является основным языком программирования, применяемым при разработке;
- PyTorch обеспечивает построение, обучение и применение нейронных сетей;
- OpenCV применяется для реализации алгоритма локализации фигуры на изображении;
- scikit-learn обеспечивает разбиение датасета и расчёт метрик качества;
- iterative-stratification используется для группового стратифицированного разбиения мультиметочных данных;
- Pillow выполняет загрузку, преобразование и сохранение изображений;
- Google Colab Notebooks предоставляет вычислительную платформу с графическим ускорителем для обучения модели;
- FastAPI, PostgreSQL, MinIO и Docker используются для оформления решения в виде микросервисного веб-сервиса.

В результате выполнения работы был разработан программный комплекс на языке Python, состоящий из модуля препроцессинга, обученной нейросетевой модели, словаря интерпретаций признаков и генератора текстового психологического портрета. Дополнительно эти компоненты

объединены в микросервисную веб-систему, развёртываемую через docker-compose, что обеспечивает доступ к функциональности через браузер без необходимости установки локального окружения.

Результаты работы могут быть использованы психологами и педагогами в образовательных и медицинских учреждениях для предварительного анализа, а также в научных исследованиях для автоматизированной обработки больших объемов детских рисунков.

1 ПРЕДМЕТНАЯ ОБЛАСТЬ И ПОСТАНОВКА ЗАДАЧИ

1.1 Рисуночные тесты как инструмент психологической диагностики

Рисуночные тесты относятся к классу проективных психодиагностических методик. Их основная идея заключается в том, что в свободном изобразительном продукте отражаются устойчивые личностные особенности, эмоциональные состояния и социальные установки автора рисунка [1]. Среди множества методик особое место занимает тест «Рисунок человека»: ребёнку предлагается нарисовать человека на чистом листе бумаги, после чего психолог анализирует получившееся изображение по большому числу формальных и содержательных критериев.

Методология интерпретации, разработанная А. Л. Венгером [1], применяется на практике российскими специалистами. Каждый рисунок описывается по более чем сотне критериев, объединённых в смысловые блоки: расположение на листе, размер рисунка, нажим, тело, ноги, одежда и другие. Каждой комбинации значений сопоставлен набор гипотетических психологических интерпретаций. Существенно, что одна и та же черта обычно поддерживается несколькими признаками рисунка одновременно, поэтому при интерпретации специалист строит общую картину, учитывая количество подтверждающих признаков.

1.2 Список психологических черт и канонические признаки рисунка

В настоящей работе использован экспертно составленный список из 26 канонических психологических черт — тревожность личностная, состояние тревоги, демонстративность, агрессивность и другие — каждая из которых снабжена кратким текстовым описанием. Список из 117 наблюдаемых признаков рисунка предоставлен научным руководителем. Признаки разделены на бинарные и категориальные.

1.3 Современные подходы к классификации изображений

Задача распознавания признаков на изображении сводится к задаче классификации: для каждого бинарного признака требуется двухклассовый

классификатор, для каждого категориального — мультиклассовый. С учётом совместного множества признаков задача относится к классу multi-label / multi-task classification.

Современным стандартом решения подобных задач являются свёрточные нейронные сети [2]. Одним из наиболее распространённых семейств таких архитектур является ResNet [3], в котором используются остаточные соединения, обеспечивающие устойчивое обучение глубоких сетей. Для multi-task обучения распространён подход с общим бэкбоном и отдельными классификационными головами для каждой задачи: совместное обучение позволяет частично разделять пространство признаков между задачами и сокращать требуемый объём данных, однако уязвимо к конкуренции градиентов. Для смягчения этого эффекта применяются взвешивание функции потерь и стратификация выборки.

Помимо собственно задачи распознавания, дополнительным аспектом разработки является способ предоставления результата конечному пользователю. Современным стандартом доставки функциональности машинного обучения в виде сервиса является микросервисная архитектура: каждый функциональный модуль системы оформляется как независимый процесс, общающийся с соседними по протоколу HTTP, а вся совокупность модулей развёртывается через систему контейнеризации. Такой подход обеспечивает технологическую независимость модулей, отказоустойчивость, простоту масштабирования и развёртывания.

1.4 Особенности задачи и подход к её решению

Особенностями детских рисунков являются малый контраст линий относительно фона, разнообразие стилей и плотности изображения, размещение фигуры в произвольной области листа, наличие посторонних деталей. Эти особенности требуют этапа предобработки — локализации фигуры на странице и извлечения её ограничивающего прямоугольника. В работе для этой задачи разработан собственный алгоритм на основе классических операций обработки изображений, что обеспечивает прозрачность и воспроизводимость поведения модуля и не требует внешних предобученных моделей детекции.

После кропа фигуры и приведения её к фиксированному квадратному размеру теряется информация о масштабе и положении фигуры на исходном

листе, существенная для ряда признаков, например: смещение. Для сохранения этой информации в работе используется двухпоточная архитектура: помимо самого изображения, в модель подаётся дополнительный вектор геометрических метаданных bounding box. Подробное описание архитектуры приводится в Главе 2.

1.5 Постановка задачи

В рамках данной работы решается следующая задача. Дан датасет из 8179 изображений детских рисунков формата png/jpeg, сопровождаемый таблицей разметки в формате CSV. Каждой записи сопоставлены значения 117 признаков, проставленные экспертами-психологами по методологии А. Л. Венгера. База изображений и разметка предоставлены Московским государственным психолого-педагогическим университетом; рисунки получены из образовательных учреждений Самарской, Московской, Вологодской областей и Республики Чувашия.

Требуется:

- разработать алгоритм предобработки изображений, обеспечивающий извлечение фигуры с произвольного листа;
- спроектировать и обучить нейросетевую модель, классифицирующую все 117 признаков по входному рисунку;
- обеспечить корректную обработку дисбаланса классов и сильной разнородности количеств положительных примеров между признаками;
- составить словарь сопоставления признаков с 26 каноническими психологическими чертами и реализовать на его основе модуль генерации текстового психологического портрета;
- провести экспериментальное исследование качества модели на тестовой выборке;
- для удобства практического использования оформить полученные модули в виде микросервисного веб-сервиса, доступного через браузер.

Целевые показатели качества по тестовой выборке — F1-мера (micro), F1-мера (weighted) и F1-мера (macro). Все три варианта усреднения приводятся параллельно: F1-мера (micro) и F1-мера (weighted) отражают долю верных предсказаний на типичных рисунках, F1-мера (macro) — качество

распознавания всех классов одновременно, в том числе минорных.

2 РАЗРАБОТКА ПРОГРАММНОГО КОМПЛЕКСА

2.1 Общая архитектура решения

Разработанная система представляет собой программный комплекс анализа детских рисунков, функционально декомпозированный на пять последовательных модулей в нотации IDEF0 [4]. Каждый модуль решает свою подзадачу и передаёт результат следующему этапу обработки. Структура декомпозиции приведена на рисунке 1.




Рисунок 1 - Функциональная декомпозиция программного комплекса анализа детских рисунков

Назначение каждого модуля следующее:

- A1. Приём и предобработка изображений — принимает исходный отсканированный рисунок и подготавливает его для нейросетевой модели: чтение и декодирование файла (A1.1), локализация фигуры

- на основе классических методов обработки изображений (A1.2), кроп и ресайз выделенной области до размера 384×384 (A1.3);
- A2. Извлечение признаков — формирует входы для нейросетевой модели: визуальные признаки кропа через свёрточный бэкбон (A2.1) и вектор bbox-метаданных из 12 геометрических характеристик (A2.2);
 - A3. Классификация признаков — ядро системы. Загружает веса обученной модели (A3.1), выполняет двухпоточный инференс (A3.2) и формирует 117 предсказаний (A3.3);
 - A4. Интерпретация результатов — транслирует предсказания модели в психологические термины с использованием словаря, построенного на основе методики А. Л. Венгера (A4.1), и подсчитывает поддержку для каждой из 26 канонических черт (A4.2);
 - A5. Формирование отчёта — ранжирует психологические черты по числу подтверждающих признаков (A5.1) и собирает связный текстовый портрет с пояснениями (A5.2).

Каждый модуль имеет чётко определённые входы и выходы, что обеспечивает прозрачность работы системы и возможность независимой замены отдельных компонентов. На уровне реализации каждый функциональный модуль вынесен в отдельный микросервис, поверх которых построен веб-интерфейс пользователя (см. подразделы 2.8–2.13).

2.2 Описание датасета и его подготовка

В работе использован датасет из 8179 отсканированных детских рисунков, полученный из образовательных учреждений Самарской области, Республики Чувашии, Московской и Вологодской областей. База изображений и разметка предоставлены Московским государственным психолого-педагогическим университетом, разметка выполнена специалистами в области детской психологии. Сопровождающая CSV-таблица содержит для каждой записи значения 117 экспертно проставленных признаков и служебные поля.

В разметке для 61 уникального кода имеется по несколько записей с возможными расхождениями значений признаков, что объясняется независимой разметкой одного и того же рисунка несколькими экспертами.

Для устранения противоречий применяется голосование большинством (majority vote) по каждому признаку независимо. После дедупликации каждому уникальному коду соответствует одна запись с консолидированной разметкой, записи без соответствующего изображения исключаются. В результате получается выборка из более 7000 примеров.

Для разбиения на обучающую, валидационную и тестовую части применяется групповое стратифицированное разбиение в пропорции 70/15/15 с использованием библиотеки `iterative-stratification` [5]. Стратификация выполняется по бинарным индикаторам редких классов наиболее сложных признаков. После дедупликации каждый код встречается ровно один раз, поэтому разбиение автоматически `group-safe`.

2.3 Модуль предобработки изображений

Модуль реализует локализацию фигуры человека на отсканированном листе и формирует кропированное квадратное изображение фиксированного размера и вектор из 12 геометрических метаданных. Алгоритм собран из классических операций библиотеки `OpenCV` [6] без использования предобученных нейронных моделей детекции, что обеспечивает прозрачность и воспроизводимость поведения модуля.

Конвейер обработки состоит из нескольких этапов. К исходному изображению, приведённому к одноканальному виду, применяется адаптивная бинаризация с гауссовым ядром, выбранная вместо глобального порога из-за неравномерной яркости сканов, затем медианная фильтрация и морфологическое замыкание для объединения близко расположенных штрихов одной фигуры в связную область. Далее с помощью `cv2.connectedComponentsWithStats` выделяются связные компоненты, каждая из которых проходит проверку по четырём независимым критериям: минимальная площадь, занимаемая доля листа, отношение сторон, плотность заполнения.

Из оставшихся кандидатов выбирается компонента с наибольшей площадью — якорная, к ней присоединяются все остальные кандидаты, чьи центры масс находятся в пределах адаптивного радиуса. Результирующий ограничивающий прямоугольник расширяется на 8 % по каждой стороне, по нему выполняется обрезка, дополнение белым фоном до квадрата и приведение к разрешению 384×384 билинейной интерполяцией.

Помимо кропа, для каждого изображения вычисляется вектор из 12 геометрических метаданных: относительные ширина, высота, площадь и координаты центра bbox; отношение высоты к ширине; четыре бинарных индикатора касания краёв листа; нормализованное расстояние от центра bbox до ближайшего угла; индикатор источника детекции. Эти метаданные используются как второй вход нейронной сети (см. подраздел 2.4) и сохраняют информацию о размере и положении фигуры на исходном листе, утрачиваемую после кропа.

2.4 Архитектура нейросетевой модели

Для классификации 117 признаков спроектирована двухпоточковая свёрточная нейронная сеть, обучаемая полностью с нуля на целевой выборке детских рисунков. Общая схема архитектуры приведена в приложении на рисунке Б.1.

Выбор обучения с нуля вместо transfer learning с предобученным бэкбоном (например, ResNet-50) мотивирован существенным отличием статистики детских карандашных рисунков от естественных фотоизображений ImageNet. ImageNet-предобучение оптимизирует свёрточные ядра под детектирование цветных текстур и градиентов яркости, в то время как карандашный рисунок представляет собой набор тёмных линий на однородном светлом фоне. В предварительных экспериментах модели на основе предобученного ResNet-50/152 не давали статистически значимого выигрыша по F1-мере над моделью, обученной с нуля, при существенно большем числе параметров (около 60 млн против 5,5 млн у разработанной модели).

Первый поток обрабатывает кропированное изображение размером 320×320 пикселей. Уменьшение разрешения с 384 до 320 выполнено для сокращения объёма вычислений на инференсе без существенной потери качества (потеря F1 в предварительных экспериментах — около 0,003). Сеть состоит из пяти этапов:

- Stem — первый свёрточный слой с ядром 7×7 , BatchNorm [7], ReLU и max-pool 3×3 со страйдом 2. Большое начальное ядро мотивировано особенностью детских рисунков: типичные карандашные штрихи длинные, и одно ядро 7×7 захватывает целые сегменты, в отличие от стандартных ядер 3×3 современных backbone'ов;

- Stage 2 (64 канала) — два residual-блока с последующим max-pool;
- Stage 3 (128 каналов) — два residual-блока с последующим max-pool;
- Stage 4 (256 каналов) — два residual-блока с последующим max-pool, выход используется как первый источник многомасштабных признаков;
- Stage 5 (384 канала) — один residual-блок, выход используется как второй источник многомасштабных признаков.

Каждый residual-блок реализует стандартную схему с двумя свёртками 3×3 , BatchNorm и ReLU и пропускающим (skip) соединением. При несовпадении числа каналов или страйда в skip-соединение добавляется проекционная свёртка 1×1 . Использование residual-связей обеспечивает устойчивое распространение градиентов в глубокой сети и облегчает оптимизацию [3].

С целью повышения детализации признакового представления используется конкатенация выходов четвёртого и пятого этапов, пропущенных через адаптивный усредняющий пулинг до размера 1×1 :

$$\mathbf{f}_{img} = [\text{pool}(\text{stage}_4(x)) ; \text{pool}(\text{stage}_5(x))] \in \mathbb{R}^{640} \quad (1)$$

Применение конкатенации признаков с двух уровней обусловлено следующими соображениями. Признаки stage 4 (256 каналов) содержат среднеуровневые геометрические паттерны (формы, очертания, локальные особенности), полезные для распознавания мелких деталей рисунка (форма глаз, наличие пуговиц, штриховка). Признаки stage 5 (384 канала) содержат высокоуровневые семантические признаки, релевантные для общих характеристик (поза фигуры, ракурс, размер). Совместное использование обоих уровней даёт богатое признаковое представление, способное обслуживать как мелкозернистые, так и крупнозернистые задачи распознавания.

Второй поток обрабатывает 12-мерный вектор геометрических метаданных, выработанных модулем предобработки. Перед подачей в сеть метаданные нормируются по среднему и стандартному отклонению, вычисленным на обучающей выборке. Преобразование выполняет двухслойный MLP с активациями ReLU и одним слоем дропаута [8]:

$$\mathbf{f}_{bbox} = \text{MLP}(\mathbf{x}_{bbox}) \in \mathbb{R}^{64} \quad (2)$$

Необходимость второго потока обусловлена тем, что после кропа и ресайза фигуры к фиксированному размеру в визуальном представлении теряется информация о её абсолютном размере и положении на исходном листе. Между тем эта информация существенна для ряда признаков рисуночного теста: «размер рисунка» определяется отношением площади фигуры к площади листа, «расположение» и «смещение» — координатами центра фигуры на странице, признак «обрезано» — касанием `bbox`-фигуры краёв листа.

Векторы признаков от двух потоков конкатенируются и пропускаются через одну из двух параллельных проекционных голов. Признаки, для которых ожидается повышенная сложность распознавания, направляются через выделенную проекцию; остальные — через общую проекцию. Такое разделение — разновидность многозадачного обучения с группировкой задач [9] — уменьшает конкуренцию градиентов между задачами разной сложности и обеспечивает более устойчивое обучение признаков с малым числом примеров. Каждая проекция сужает признаковое пространство до 256 нейронов с дропаутом 0,3.

Финальный слой состоит из 117 параллельных классификационных голов: каждая голова — один линейный слой, отображающий 256-мерный признак в логиты соответствующего числа классов (2 для бинарного признака, K для категориального с K классами). Все 117 голов организованы в виде `nn.ModuleDict`, что обеспечивает прозрачную адресацию к голове по имени критерия и упрощает сохранение и загрузку модели.

Общее число параметров модели составляет около 5,5 миллионов, размер сохранённого чекпоинта — около 22 МБ. Инициализация всех свёрточных и линейных слоёв выполнена методом Кайминга [10], что соответствует выбранной активации ReLU и обеспечивает корректное масштабирование начальных активаций по слоям. На рисунке 2 представлен фрагмент реализации определения архитектуры модели и процедуры обучения.

```

1 class ResidualBlock(nn.Module):
2     def __init__(self, in_ch, out_ch, stride=1):
3         super().__init__()
4         self.conv1 = nn.Conv2d(in_ch, out_ch, 3,
5                                 stride=stride, padding=1, bias=False)
6         self.bn1 = nn.BatchNorm2d(out_ch)
7         self.conv2 = nn.Conv2d(out_ch, out_ch, 3, padding=1, bias=
8                                 False)
9         self.bn2 = nn.BatchNorm2d(out_ch)
10        if stride != 1 or in_ch != out_ch:
11            self.shortcut = nn.Sequential(
12                nn.Conv2d(in_ch, out_ch, 1, stride=stride, bias=
13                           False),
14                nn.BatchNorm2d(out_ch))
15        else:
16            self.shortcut = nn.Identity()
17    def forward(self, x):
18        out = F.relu(self.bn1(self.conv1(x)), inplace=True)
19        out = self.bn2(self.conv2(out))
20        out = out + self.shortcut(x)
21        return F.relu(out, inplace=True)

```

Рисунок 2 - Фрагмент кода реализации обучения

2.5 Функции потерь и стратегия обучения

Для бинарного признака используется взвешенная перекрёстная энтропия с весами классов $\alpha = (1.0, \min(\sqrt{N_-/N_+}, 10))$, где $N_{\pm}$ — количества отрицательных и положительных примеров. Корень из отношения и ограничение значением 10 защищают градиент от взрыва при экстремальном дисбалансе. В качестве альтернативы рассматривалась фокальная функция потерь [11], однако сочетание корневого взвешивания и WeightedRandomSampler даёт сопоставимое поведение при меньшем числе гиперпараметров для подбора.

Для категориального признака используется взвешенная перекрёстная энтропия с label smoothing 0.05 и весами $\alpha_i = \min(\sqrt{N_{max}/N_i}, 10)$. Совокупная функция потерь — среднее по 117 признакам:

$$\mathcal{L} = \frac{1}{117} \sum_{i=1}^{117} \mathcal{L}_i(\mathbf{f}_{proj}, y_i) \quad (3)$$

Дополнительно применяется `WeightedRandomSampler`: каждому примеру обучающей выборки присваивается вес, повышенный относительно базового для тех примеров, которые имеют положительные метки редких классов. Веса ограничены диапазоном $[1, 2.5]$, сэмплирование выполняется с возвращением. На рисунке 3 приведён фрагмент реализации цикла обучения с вычислением функций потерь и обновлением параметров модели.

```
1 opt = torch.optim.AdamW(model.parameters(),
2                           lr=1e-4, weight_decay=5e-4)
3
4 for epoch in range(50):
5     lr_mult = cosine_warmup(epoch, total=50, warmup=3)
6     for pg in opt.param_groups:
7         pg['lr'] = pg['_base_lr'] * lr_mult
8
9     model.train()
10    for imgs, bboxes, labels in train_loader:
11        imgs, bboxes = imgs.to(device), bboxes.to(device)
12        opt.zero_grad()
13        logits = model(imgs, bboxes)
14        total = 0.0
15        for name in criteria:
16            tg = labels[name].to(device)
17            total = total + loss_fns[name](logits[safe[name]], tg)
18        loss = total / len(criteria)
19        loss.backward()
20        torch.nn.utils.clip_grad_norm_(model.parameters(), 1.0)
21        opt.step()
22
23    f1 = validate(model, val_loader)
24    if f1 > best_f1:
25        torch.save(model.state_dict(), 'best.pth')
26        best_f1 = f1
```

Рисунок 3 - Фрагмент кода реализации цикла обучения

К каждому изображению применяется набор аугментаций: `random affine` ($\pm 6^\circ$, сдвиг до 5%, масштаб 90–110%), `random crop` из увеличенного на 32 пикселя изображения до 320×320 , `color jitter` (яркость и контраст до 15%), `random erasing` с вероятностью 0,2. Намеренно не используется

горизонтальное отражение, поскольку ряд признаков содержит указание на правую и левую стороны.

Оптимизатор — AdamW [12; 13] с базовой скоростью обучения 10^{-4} , weight decay $5 \cdot 10^{-4}$, обрезкой нормы градиента до 1,0. Размер пакета — 32. Расписание LR — косинусное затухание с разогревом в течение трёх эпох [14]. Смешанная точность намеренно отключена в пользу одинарной (fp32): при обучении с нуля и сильных весовых коэффициентах функции потерь начальные градиенты могут принимать большие значения, и в режиме fp16 это иногда приводит к численным переполнениям. Полное число эпох — 50 с ранней остановкой по отсутствию улучшения F1 на валидации в течение 8 эпох с минимумом в 25 эпох.

2.6 Словарь интерпретаций признаков

Связь между техническими признаками рисунка и психологическими чертами реализована через JSON-словарь `criteria_interpretations.json` объёмом около 60 КБ. Структура словаря: раздел `traits` — 26 канонических черт с текстовыми описаниями; раздел `criteria` — 117 признаков с указанием типа, набора связанных черт; раздел `meta` — сведения о версии и источниках. Содержательная составляющая построена на основе книги А. Л. Венгера [1].

Один признак может быть индикатором нескольких черт, а одна черта обычно поддерживается набором различных признаков. При использовании словаря в составе генератора портрета каждой черте сопоставляется счётчик поддержки, равный количеству предсказанных моделью признаков, ассоциированных с ней. Это позволяет ранжировать черты в итоговом тексте по степени их выраженности. В таблице 1 приведена часть канонических черт.

Таблица 1 - Часть канонических психологических черт

Черта	Краткое пояснение
Тревожность личностная	Устойчивая склонность к беспокойству, сниженная самооценка
Состояние тревоги	Ситуативная тревога, проявленная в момент рисования
Демонстративность	Стремление быть в центре внимания, экспансивное поведение
Агрессивность	Склонность к враждебному, конкурентному поведению

2.7 Генератор текстового психологического портрета

Модуль принимает на вход словарь предсказаний модели $\{c_i \mapsto v_i\}_{i=1}^{117}$ и словарь интерпретаций. Для каждого признака с положительным предсказанием ($v_i \neq 0$, $v_i \neq$ пусто) извлекается соответствующий список черт, и для каждой черты t инкрементируется счётчик поддержки:

$$S(t) = \sum_{i=1}^{117} \mathbb{1}[t \in \text{traits}(c_i, v_i)] \quad (4)$$

Параллельно для каждой черты накапливается список свидетельств — пар «признак, значение», давших вклад в её поддержку.

Финальный текст портрета содержит заголовок и краткое пояснение, перечень из 7 наиболее устойчиво проявленных черт с порогом поддержки не менее 2 признаков — для каждой приводится описание и до 4 подтверждающих свидетельств, — раздел менее устойчивых тенденций с поддержкой 1 признака и итоговое замечание о вероятностном характере выводов. Объём типового портрета — 25–40 строк. На рисунке 4 представлен фрагмент кода, реализующий логику формирования психологического портрета на основе предсказаний модели и словаря интерпретаций.

```

1 from collections import Counter, defaultdict
2
3 def compute_trait_support(predictions, criteria_dict):
4     support = Counter()
5     evidence = defaultdict(list)
6     for crit_name, value in predictions.items():
7         if value in (0, '', None):
8             continue
9         entry = criteria_dict['criteria'].get(crit_name)
10        if not entry:
11            continue
12        if entry['kind'] == 'binary_presence':
13            traits = entry.get('traits', [])
14        else:
15            traits = entry.get('class_traits', {}).get(value, [])
16        for t in traits:
17            support[t] += 1
18            evidence[t].append((crit_name, value))
19    return support, evidence

```

Рисунок 4 - Фрагмент кода для генерации психологического портрета

2.8 Микросервисная архитектура веб-сервиса

Программный комплекс реализован в виде микросервисного веб-приложения, архитектура которого представлена на рисунке 5. Система разделена на три логических контура, объединённых единым API-шлюзом.




Рисунок 5 - Архитектура веб-сервиса: микросервисы, протоколы взаимодействия и контуры хранения данных

API-шлюз (FastAPI) — единственная точка входа для внешнего пользователя. Принимает HTTP/REST-запросы от веб-браузера, оркестрирует последовательные вызовы к внутренним сервисам и возвращает итоговый HTML-отчёт. Шлюз также отвечает за сохранение изображений в объектное хранилище (S3 API) и метаданных анализа в реляционную базу (SQL).

Контур обработки изображений включает три сервиса, образующих последовательный конвейер:

- сервис приёма и предобработки (FastAPI, OpenCV) — принимает исходное изображение, выполняет локализацию фигуры и возвращает нормализованное изображение и координаты bbox;
- сервис извлечения признаков (PyTorch) — вычисляет 12-мерный вектор геометрических метаданных на основе координат bbox;
- сервис нейросетевого инференса (PyTorch) — загружает обученную модель и выполняет классификацию: принимает изображение и вектор признаков, возвращает вероятности 117 классов.

Между сервисами контура данные передаются по REST: нормализованное изображение и вектор признаков последовательно проходят через конвейер. Результат классификации в виде вероятностей классов передаётся в следующий контур.

Контур аналитики и отчётов включает два сервиса:

- а) сервис интерпретации результатов (FastAPI) — принимает вектор вероятностей классов и транслирует его в психологические черты с использованием методической базы интерпретаций (JSON-словарь, построенный по методике А. Л. Венгера);
- б) сервис формирования отчётов (FastAPI, Jinja2) — принимает интерпретацию и формирует HTML-документ психологического портрета, который возвращается API-шлюзу.

Контур хранения данных обеспечивает персистентность:

- база данных (PostgreSQL) — хранит метаданные анализов, предсказания модели, поддержку черт и сгенерированные портреты;
- хранилище изображений (MinIO) — хранит исходные сканы рисунков и результаты предобработки через S3-совместимый интерфейс.

Все внутренние сервисы взаимодействуют по протоколу REST через локальную docker-сеть. Внешний доступ открыт только для API-шлюза (порт 8000); остальные сервисы изолированы от внешних запросов, что снижает поверхность атаки.

Такая архитектура обеспечивает независимое масштабирование отдельных компонентов — при увеличении нагрузки можно горизонтально масштабировать только сервис инференса, — технологическую независимость сервисов, отказоустойчивость, при которой сбой одного сервиса не приводит к падению системы, и возможность замены модели без затрагивания остальных компонентов.

Состав сервисов и их порты приведены в таблице 2.

Таблица 2 - Состав микросервисов программного комплекса

Сервис	Порт	Назначение
api-gateway	8000	Веб-интерфейс, оркестрация цепочки, сохранение результата в БД и MinIO
preprocessing	8001	Локализация фигуры (OpenCV + YOLO-резерв), кроп и ресайз до 384×384
features	8002	Вычисление 12 геометрических bbox-признаков
inference	8003	Нейросетевой инференс: (image, bbox) $\mapsto$ 117 предсказаний
interpretation	8004	Маппинг 117 предсказаний $\rightarrow$ 26 психологических черт
report	8005	Рендер HTML-портрета по шаблону Jinja2

2.9 Технологический стек

В качестве основного языка разработки выбран Python 3.11 ввиду того, что обученная нейросетевая модель и алгоритмы предобработки изображений уже реализованы на этом языке. Для построения REST-сервисов используется фреймворк FastAPI [15] с автоматической генерацией OpenAPI-схемы и валидацией входных данных через Pydantic. ASGI-сервер — Uvicorn [16].

Сервис инференса использует библиотеку PyTorch [17] для загрузки и выполнения нейросетевой модели, сервис предобработки — библиотеки OpenCV [6] (адаптивная бинаризация, морфология, выделение связанных компонент) и Ultralytics (резервный YOLOv8-детектор [18]). Для межсервисного взаимодействия по HTTP используется асинхронный клиент httpx, шаблонизатор для HTML-портретов и веб-интерфейса — Jinja2.

Сервис api-gateway взаимодействует с внешними системами хранения через стандартизированные клиенты: psycopg (PostgreSQL) и minio (MinIO S3-совместимое объектное хранилище). Все библиотечные зависимости каждого сервиса вынесены в requirements.txt и устанавливаются изолированно при сборке образа.

2.10 Описание сервисов

api-gateway — единственная точка входа для пользователя. Предоставляет HTML-форму загрузки рисунка на главной странице, страницу истории анализов и страницу повторного просмотра сохранённого портрета по его идентификатору. При получении нового запроса сервис генерирует

UUID анализа, последовательно вызывает остальные сервисы, сохраняет промежуточные результаты в MinIO, а финальный результат — в PostgreSQL. HTML-шаблоны (форма загрузки, история, страница ошибки) выполнены на Jinja2.

`preprocessing` — реализует алгоритм локализации фигуры из подраздела 2.3. На вход поступает multipart-файл изображения, на выход — base64-кодированный кроп размером 384×384 , координаты bbox на исходном листе, размеры исходного изображения и индикатор источника детекции. Если основной OpenCV-алгоритм не обнаруживает достаточно крупной связной области, выполняется резервная детекция через YOLOv8 — готовый детектор людей используется в роли подстраховки, что повышает робастность системы к редким сложным случаям сканирования.

`features` — лёгкий вычислительный сервис, принимающий координаты bbox и размеры исходного листа и возвращающий вектор из 12 геометрических признаков, описанных в подразделе 2.3. Сервис не содержит ML-зависимостей, выполняется в считанные миллисекунды и легко горизонтально масштабируется.

`inference` — ядро системы. При запуске контейнера загружает веса обученной модели, словари label encoders, а также маски target/nontarget, восстановленные из вспомогательного pickle-файла encoders.pkl. На вход принимает изображение и 12-мерный вектор bbox-фичей; на выход выдаёт словарь 117 предсказаний и сопутствующих confidences (значения softmax по предсказанному классу). Сервис не требует GPU — инференс выполняется на CPU за порядка 0,2 секунды на одно изображение.

`interpretation` — применяет словарь criteria_interpretations.json к 117 предсказаниям, формирует словарь поддержки 26 черт и список свидетельств (см. подраздел 2.7). Логика модуля не содержит обучаемых параметров и реализована на чистом Python.

`report` — финальный шаг конвейера. Принимает словарь черт, список свидетельств и (опционально) ссылки на изображения в MinIO, формирует HTML-документ психологического портрета по шаблону Jinja2 с применением CSS-стилей. Сгенерированный HTML возвращается обратно api-gateway, который сохраняет его в PostgreSQL и отдаёт пользователю.

2.11 Хранение данных

Хранение данных распределено между двумя внешними системами в соответствии с типами хранимых данных.

Реляционная СУБД PostgreSQL [19] версии 16 хранит метаданные анализов: уникальный идентификатор, временную метку, оригинальное имя файла, ключи в объектном хранилище, источник детекции, словарь 117 предсказаний, словарь поддержки 26 черт и сгенерированный HTML-портрет. Структура одной таблицы `analyses` приведена в приложении. На полях временной метки и источника детекции созданы B-tree индексы для ускорения выборки в истории анализов. Хранение предсказаний и поддержки в виде JSONB позволяет гибко расширять формат без миграций схемы.

Объектное хранилище MinIO [20] хранит бинарные файлы — исходные сканы рисунков и кропы, выработанные модулем предобработки. Ключи объектов имеют структуру `drawings/{analysis_id}/{original|cropped}.png`, что обеспечивает однозначное соответствие между записью в PostgreSQL и связанными с ней файлами. MinIO выбран в качестве замены прямого хранения файлов в файловой системе по нескольким причинам: совместимый с Amazon S3 интерфейс упрощает миграцию в облако; встроенная веб-консоль обеспечивает прямой доступ к содержимому для администратора; разделение бинарных файлов и метаданных согласуется с микросервисной идеологией.

Такое разделение обеспечивает выполнение основного принципа проектирования: метаданные хранятся в РСУБД, где они индексируются и связываются по отношениям, а бинарные файлы — в объектном хранилище, где их объём не влияет на производительность РСУБД.

2.12 Контейнеризация и развёртывание

Все сервисы и системы хранения упакованы в Docker-контейнеры [21]; для запуска используется единый файл `docker-compose.yml`, описывающий граф зависимостей между сервисами, переменные окружения, тома для постоянного хранения данных и проброс портов. Сборка каждого сервиса выполняется из собственного `Dockerfile` в каталоге `services/<service-name>/`; общие данные (веса модели, словари) монтируются как `read-only` том из директории `shared/data/` в путь `/data`

внутри контейнеров.

В составе `docker-compose.yml` выделены три логических контура: контур обработки изображений (`preprocessing`, `features`, `inference`), контур аналитики и отчётов (`interpretation`, `report`), контур хранения (`postgres`, `minio`). Шлюз `api-gateway` оркестрирует обращения ко всем трём контурам и предоставляет единый внешний интерфейс на порту 8000. Дополнительно описан профиль `tools`, в котором одноразово запускается утилита `encoders-builder`, собирающая из исходных CSV-таблиц консолидированный `pickle`-файл с `label encoders` для сервиса инференса.

Все сервисы конфигурируются через переменные окружения, перечисленные в файле `.env`, что позволяет менять конфигурацию (имена базы, пароли, URL внутренних сервисов) без пересборки образов. Для запуска полного стека достаточно одной команды `docker compose up`, что упрощает развёртывание на новом сервере или локальной машине разработчика.

2.13 Поток данных при анализе одного рисунка

При загрузке нового рисунка через веб-интерфейс выполняется следующая последовательность обращений между сервисами:

- а) `api-gateway` принимает HTTP POST с файлом изображения, генерирует идентификатор анализа (UUID), сохраняет оригинал в MinIO по ключу `drawings/{id}/original.png`;
- б) обращение к `preprocessing/crop` — модуль возвращает кроп в base64, координаты `bbox`, размеры исходного изображения и источник детекции;
- в) полученный кроп сохраняется в MinIO по ключу `drawings/{id}/cropped.png`;
- г) обращение к `features/compute` с координатами `bbox` и размерами оригинала — модуль возвращает вектор из 12 геометрических признаков;
- д) обращение к `inference/predict` с изображением и вектором `bbox`-фичей — модуль возвращает 117 предсказаний и их `confidences`;
- е) обращение к `interpretation/derive` с 117 предсказаниями — модуль возвращает поддержку 26 черт и список свидетельств;
- ж) обращение к `report/render` с данными о чертах и свидетельствами

- модуль возвращает HTML-документ психологического портрета;
- и) `api-gateway` сохраняет в Postgres метаданные анализа (идентификатор, ключи в MinIO, предсказания, поддержку черт, HTML-портрет) и возвращает HTML пользователю.

Все обращения между сервисами выполняются по локальной `docker`-сети с использованием доменных имён сервисов (например, `http://inference:8003/predict`), не выходят за пределы хоста и не предполагают аутентификации. Пользовательский интерфейс взаимодействует только с `api-gateway` через порт 8000.

Сохранённый результат доступен в дальнейшем через раздел истории анализов и может быть открыт повторно по идентификатору без выполнения цепочки заново — сохранённый HTML-портрет извлекается из PostgreSQL и отдаётся пользователю без обращения к остальным сервисам. Это обеспечивает быстрый просмотр уже выполненных анализов и снижает нагрузку на сервис инференса.

3 ЭКСПЕРИМЕНТАЛЬНОЕ ИССЛЕДОВАНИЕ

3.1 Условия проведения экспериментов

Все эксперименты проводились в облачной среде Google Colab Notebooks с использованием графического ускорителя NVIDIA Tesla T4, 16 ГБ видеопамати. Программное окружение: Python 3.10, PyTorch 2.x с поддержкой CUDA, библиотеки torchvision, opencv-python, pandas, scikit-learn, iterative-stratification.

Размер пакета при обучении — 32 примера, размер изображения — 320×320 пикселей, число эпох — 50 с ранней остановкой. Время обучения одной эпохи составляет около 60 секунд, полный цикл обучения занимает около 30–50 минут в зависимости от срабатывания ранней остановки.

Воспроизводимость обеспечивается фиксированным значением `random_state = 42` для всех источников случайности: разбиения выборки, инициализации весов сети, перемешивания данных и взвешенного сэмплирования.

3.2 Метрики качества

Для оценки качества модели применяются три варианта F1-меры [22]:

- $F1_{\text{micro}}$ — F1, вычисленная по агрегированной матрице ошибок с одинаковым весом каждого предсказания. В целом, можно сказать близка к ассигасу и отражает общую долю правильных предсказаний;
- $F1_{\text{weighted}}$ — среднее F1 по классам с весами, пропорциональными количеству примеров каждого класса в выборке. Учитывает редкость классов, не штрафует избыточно за их пропуск;
- $F1_{\text{macro}}$ — среднее значение F1 по классам каждого признака с равными весами для всех классов независимо от их частоты.

Чувствительна к качеству модели на минорных классах.

Формально метрики определяются следующим образом. Для каждого класса c определяются количества истинно положительных (TP_c), ложно положительных (FP_c) и ложно отрицательных (FN_c) предсказаний. Точность (precision) и полнота (recall) для класса c :

$$P_c = \frac{TP_c}{TP_c + FP_c}, \quad R_c = \frac{TP_c}{TP_c + FN_c} \quad (5)$$

$F1_{\text{micro}}$ агрегирует TP, FP, FN по всем классам перед вычислением:

$$F1_{\text{micro}} = \frac{2 \sum_c TP_c}{2 \sum_c TP_c + \sum_c FP_c + \sum_c FN_c} \quad (6)$$

$F1_{\text{macro}}$ вычисляет F1 для каждого класса отдельно и усредняет с равным весом:

$$F1_{\text{macro}} = \frac{1}{C} \sum_{c=1}^C \frac{2 P_c \cdot R_c}{P_c + R_c} \quad (7)$$

$F1_{\text{weighted}}$ усредняет F1 по классам с весами, пропорциональными числу примеров n_c каждого класса:

$$F1_{\text{weighted}} = \frac{\sum_{c=1}^C n_c \cdot F1_c}{\sum_{c=1}^C n_c} \quad (8)$$

Каждая из трёх метрик имеет своё практическое значение. $F1_{\text{micro}}$ и $F1_{\text{weighted}}$ отражают качество системы на типичных рисунках — то, как часто модель будет давать корректное предсказание для произвольно выбранного образца. $F1_{\text{macro}}$ показывает, насколько хорошо модель справляется со всеми классами одновременно, в том числе с теми, которые встречаются редко. В работе все три метрики приводятся параллельно, без выбора одной из них в качестве главной.

В качестве итоговых показателей по всем 117 признакам используются средние значения F1 каждого вида, рассчитанные как среднее арифметическое по 117 признакам.

3.3 Результаты на тестовой выборке

Результаты, полученные разработанной моделью на тестовой выборке, которая составляет около 1000 рисунков, приведены в таблице 3.

Таблица 3 - Метрики качества на тестовой выборке

Метрика	Значение
$F1_{\text{micro}}$	0,901
$F1_{\text{weighted}}$	0,875
$F1_{\text{macro}}$	0,521

Значение $F1_{\text{micro}} = 0,901$ означает, что модель корректно классифицирует около 90% всех предсказаний по 117 признакам в совокупности. Близкое к нему значение $F1_{\text{weighted}} = 0,875$ подтверждает устойчивость качества при учёте различной частоты классов. Отличия между двумя метриками невелики, что указывает на отсутствие систематического перекося в сторону какой-либо группы классов.

Заметно более низкое значение $F1_{\text{macro}} = 0,521$ объясняется особенностями выборки и формулы метрики. $F1_{\text{macro}}$ штрафует модель за каждый минорный класс, который она не научилась распознавать, причём с равным весом независимо от размера класса. В рассматриваемом датасете 10 из 117 признаков имеют менее десяти положительных примеров в обучающей выборке. Для таких признаков модель в большинстве случаев предсказывает мажоритарный класс, что обеспечивает высокую общую точность, но низкую $F1$ -меру по минорному классу. Эти 10 признаков существенно опускают среднее значение $F1_{\text{macro}}$, не влияя при этом на $F1_{\text{micro}}$ и $F1_{\text{weighted}}$.

При этом по ряду конкретных признаков разработанная модель превосходит результаты предыдущей базовой версии ResNet-152. В таблице 4 приведены признаки, для которых удалось улучшить метрику $F1_{\text{macro}}$.

Таблица 4 - Признаки с улучшением $F1_{\text{macro}}$ относительно базовой модели

Признак	Базовая	Разработанная	Прирост
размер глаз большие	0,832	1,000	+0,168
форма глаз большие	0,856	1,000	+0,144
ступни отсутствуют	0,500	0,643	+0,143

Улучшение по данным признакам объясняется тем, что разработанная модель обучена с нуля на целевом домене карандашных рисунков без использования ImageNet-предобучения. Свёрточные фильтры, настроенные

непосредственно на штриховые изображения, более чувствительны к тонким различиям в пропорциях элементов (размер и форма глаз) и наличию/отсутствию мелких деталей (ступни).

3.4 Анализ распределения метрик по признакам

Распределение значений $F1_{\text{weighted}}$ по 117 признакам приведено на рисунке 6.




Рисунок 6 - Распределение $F1_{\text{weighted}}$ по 117 признакам

Подавляющее большинство признаков имеет значение $F1_{\text{weighted}}$ в диапазоне 0,85–0,99, что подтверждает однородно высокое качество модели по совокупности задач.

Среди 117 признаков особо выделяются 10 признаков с экстремально малым числом положительных примеров (менее 10 в обучающей выборке). Для них объём данных принципиально не позволяет обучить классификатор, надёжно распознающий минорный класс: модель в большинстве случаев предсказывает мажоритарный класс, что обеспечивает высокое значение $F1_{\text{weighted}}$ (близкое к 1) и низкое значение $F1_{\text{macro}}$ (около 0,5). Эти признаки оказывают значительное влияние на среднее значение $F1_{\text{macro}}$ по всей выборке, но практически не влияют на $F1_{\text{micro}}$ и $F1_{\text{weighted}}$.

В целом распределение метрик показывает, что модель успешно справляется с задачей классификации признаков рисунка для типичных рисунков. Снижение $F1_{\text{macro}}$ обусловлено редкими признаками, для которых при имеющемся объёме обучающих данных надёжная классификация минорного класса принципиально невозможна.

3.5 Демонстрация работы программного комплекса

Для демонстрации работы веб-сервиса загрузим рисунок из тестовой выборки через пользовательский интерфейс и проследим результат на каждом этапе конвейера.


На рисунке 7 представлена верхняя часть страницы результата: заголовок, метаданные об анализе (число активных предсказаний, уникальный идентификатор), а также сравнение исходного отсканированного листа и результата предобработки — кропированной и нормализованной фигуры.

Психологический портрет по рисунку человека

Анализ методом А.Л. Венгера. Активных предсказаний: 26 из 117.
ID: 85fcabb7ac8b4dbc9ff83871659c143d



Оригинал



После предобработки

Рисунок 7 - Веб-интерфейс результата анализа: заголовок, метаданные и сравнение исходного изображения с результатом предобработки

После прохождения изображения через нейросетевую модель 117 предсказаний транслируются через словарь интерпретаций в психологические черты. На рисунке 8 показан раздел «Ключевые особенности» — черты с поддержкой не менее двух признаков, ранжированные по степени выраженности. Для каждой черты указаны описание и список подтверждающих свидетельств.

Помимо интерпретации, веб-интерфейс отображает технические детали работы модели. На рисунке 9 приведена таблица десяти наиболее уверенных активных предсказаний с указанием имени признака, предсказанного значения и confidence (значение softmax).

Ключевые особенности

1. Уверенность (поддержка: 3 призна.)

уверенность в себе, устойчивая самооценка.

Подтверждается: «расположение на листе | смещение вниз/5»; «степень смещения вниз» = сильно/2; «ступни | отсутствуют/6»

2. Состояние тревоги (один признак, без сочетаний) (поддержка: 2 призна.)

тревога как состояние на момент обследования.

Подтверждается: «аккуратность штриховки | низкая/2»; «размер рисунка» = Очень крупный/5

3. Признаки отклонения от нормы (поддержка: 2 призна.)

признаки органических, психических или развивающих нарушений.

Подтверждается: «грубые нарушения рисунка | нарушение пропорций/3»; «шея | отсутствует/7»

4. Интроверсия (поддержка: 2 призна.)

интровертная направленность, ограничение контактов.

Подтверждается: «изображение в рамке» = нет/2; «кисть | отсутствует/6»

5. Импульсивность (поддержка: 2 призна.)

склонность действовать без обдумывания, реактивность.

Подтверждается: «размер рисунка» = Очень крупный/5; «шея | отсутствует/7»

**Рисунок 8 - Раздел «Ключевые особенности»
сгенерированного психологического портрета**

Топ-10 активных предсказаний модели

персонаж	нет/2	0.75
изображение в рамке	нет/2	0.73
ракурс	Стандарт (фас) /1	0.66
расположение на листе смещение вниз/5	1	0.65
голова большая/3	1	0.61
нажим без особенностей/1	1	0.60
изображение персонажа	нет/2	0.59
поза	Стоит/1	0.57
фигура в движении	нет/2	0.56
ступни отсутствуют/6	1	0.56

Рисунок 9 - 10 активных предсказаний модели

3.6 Анализ временных характеристик

Измерены характеристики времени работы программного комплекса в инференс-режиме на NVIDIA Tesla T4. Обработка одного рисунка от подачи на вход сырого изображения до возврата итогового текстового портрета занимает в среднем около 0,4 секунды. Это время разбивается на следующие компоненты:

- чтение и декодирование изображения из файла — около 0,05 с;
- локализация фигуры (адаптивная бинаризация, морфология, выделение связных компонент, фильтрация и объединение) — около 0,15 с;

- кроп, паддинг, ресайз — менее 0,01 с;
- инференс — около 0,18 с (один прямой проход на одном изображении);
- декодирование 117 предсказаний и применение словаря интерпретаций — менее 0,01 с;
- ранжирование черт и формирование итогового текста — менее 0,01 с.

При пакетной обработке (batch inference) среднее время на один рисунок снижается за счёт лучшего использования параллелизма GPU: при обработке пакета из 32 рисунков время на одно изображение составляет около 0,05 секунд.

Время обучения модели от начала до завершения — порядка 30–50 минут на одном NVIDIA Tesla T4 (50 эпох с ранней остановкой). Размер сохранённого чекпоинта — около 22 МБ. Эти характеристики делают разработанный комплекс полностью применимым в практических условиях: при наличии современного GPU психолог может обработать пакет из сотен рисунков за несколько минут.

3.7 Тестирование веб-сервиса

Для верификации корректной работы микросервисной системы в целом проведено функциональное и нагрузочное тестирование развёрнутого веб-сервиса. Тестирование выполнялось на локальной машине (CPU: Intel Core i5, 16 ГБ ОЗУ) в режиме Docker-контейнеров без GPU.

Функциональное тестирование. Проверена корректность работы полного конвейера end-to-end: загрузка изображения через веб-форму, прохождение всех этапов обработки, формирование психологического портрета и сохранение результата в базу данных. Протестированы следующие сценарии:

- загрузка типичного отсканированного рисунка формата A4 (2480×3508, ~1 МБ) — успешная обработка, портрет сгенерирован;
- загрузка фотографии рисунка с мобильного устройства (4032×3024, ~3 МБ) — успешная обработка;
- загрузка изображения без фигуры (чистый лист) — система возвращает портрет без выраженных особенностей;
- загрузка файла некорректного формата — корректная обработка ошибки с информативным сообщением;
- повторный просмотр сохранённого анализа по идентификатору —

портрет загружается из БД без повторного инференса.

Измерение времени отклика. Время обработки одного запроса (от отправки файла до получения HTML-портрета) при последовательной обработке составляет:

Таблица 5 - Время обработки одного рисунка через веб-сервис (CPU-режим)

Этап	Время, с
Предобработка (OpenCV-локализация)	0,3–0,5
Вычисление bbox-признаков	< 0,01
Нейросетевой инференс (CPU)	1,5–2,5
Интерпретация и формирование портрета	< 0,05
Сохранение в MinIO и PostgreSQL	0,1–0,2
Итого end-to-end	2,0–3,2

Основное время занимает инференс на CPU. При развёртывании с GPU (NVIDIA Tesla T4) время инференса сокращается до $\sim 0,2$ с, а общее время отклика — до $\sim 0,7$ с.

Нагрузочное тестирование. При параллельной отправке 10 запросов в секунду система обрабатывает все запросы без ошибок с линейным ростом латентности (запросы ставятся в очередь к единственному экземпляру сервиса инференса). При необходимости обслуживания большего числа одновременных пользователей достаточно горизонтально масштабировать сервис инференса (запуск нескольких реплик через Docker Compose).

Тестирование устойчивости. Проверена реакция системы на аварийные ситуации: при принудительной остановке контейнера inference API-шлюз возвращает корректное сообщение об ошибке; после перезапуска контейнера система восстанавливает работоспособность без ручного вмешательства благодаря директиве `restart: unless-stopped`. История ранее выполненных анализов остаётся доступной, поскольку хранится в PostgreSQL.

3.8 Сфера применения и ограничения

Разработанный программный комплекс может применяться психологами, педагогами и исследователями детской психологии в следующих сценариях.

Первый — предварительный скрининг в детских садах и школах. Психолог может пропустить пакет рисунков через систему за минуты вместо часов и получить ранжированный список рисунков, требующих более детального индивидуального анализа.

Второй — исследовательские задачи, в которых требуется обработка больших коллекций рисуночных тестов. Например, выявление средних тенденций в группе по полу или возрасту, корреляций психологических характеристик с социальными факторами, динамики изменения психологических черт со временем.

Третий — учебные курсы по практической психологической диагностике. Система может применяться для демонстрации связи признаков рисунка с психологическими интерпретациями.

Среди ограничений разработки следует отметить следующие:

- а) система предназначена исключительно для теста «Рисунок человека» и не может быть напрямую применена к другим рисуночным тестам («Дом-Дерево-Человек», «Несуществующее животное», «Моя семья» и др.) без переобучения. Возможна адаптация архитектуры для других тестов при наличии аналогичной обучающей выборки;
- б) выводы системы носят гипотетический характер и не могут заменить непосредственное общение специалиста с ребёнком, сбор анамнеза и наблюдение за ребёнком в естественных условиях. Психологический портрет, сгенерированный системой, является лишь предварительной гипотезой и должен подтверждаться независимыми источниками;
- в) точность предсказаний для редко встречающихся признаков объективно ограничена объёмом обучающих данных и требует осторожной интерпретации. Если итоговый портрет содержит черту, поддерживаемую только одним признаком, имеет смысл отнестись к ней с осторожностью; черты, поддерживаемые тремя и более признаками, существенно более надёжны;
- г) система обучена на рисунках детей дошкольного и младшего школьного возраста (приблизительно 5–12 лет). Для рисунков существенно других возрастных групп (подростков и взрослых) качество предсказаний может оказаться ниже, поскольку их

- рисуночные продукты имеют другие стилистические особенности;
- д) применение системы требует наличия отсканированного или сфотографированного рисунка достаточного качества. Сильно повреждённые, размытые или с фрагментированной фигурой изображения могут давать неустойчивые предсказания.

Указанные ограничения не препятствуют практическому применению системы при учёте описанных условий и интерпретации её выводов как вспомогательных, а не окончательных.

ЗАКЛЮЧЕНИЕ

В результате выполнения выпускной квалификационной работы бакалавра был разработан программный комплекс автоматического распознавания визуальных признаков детских рисунков и сопоставления их с психологическими характеристиками ребёнка нейросетевыми методами. Были решены следующие задачи:

- проведён анализ предметной области рисуночных тестов и существующих подходов к автоматизации их интерпретации;
- разработан собственный алгоритм предобработки изображений, реализующий локализацию фигуры человека на листе на основе классических операций обработки изображений (адаптивная бинаризация, морфологические операции замыкания, выделение связанных компонент, фильтрация и объединение по якорной стратегии);
- спроектирована и обучена двухпоточная собственная свёрточная нейросетевая модель (около 5,5 млн параметров) для одновременной классификации 117 признаков рисунка;
- реализована стратегия обучения, устойчивая к сильному дисбалансу классов: взвешенная перекрёстная энтропия с насыщением весов классов, label smoothing для категориальных признаков, взвешенное случайное сэмплирование, групповое стратифицированное разбиение выборки;
- составлен словарь сопоставления 117 технических признаков с 26 каноническими психологическими чертами на основе методики А. Л. Венгера;
- реализован модуль генерации текстового психологического портрета с ранжированием черт по числу подтверждающих признаков;
- разработан микросервисный веб-сервис, объединяющий все модули в единый конвейер обработки с пользовательским интерфейсом, доступным через браузер;
- проведено экспериментальное исследование качества модели на тестовой выборке и функциональное тестирование веб-сервиса.

На тестовой выборке разработанная система достигла следующих показателей качества: $F1_{\text{micro}} = 0,901$, $F1_{\text{weighted}} = 0,875$, $F1_{\text{macro}} = 0,521$.

Значения $F1_{\text{micro}}$ и $F1_{\text{weighted}}$ означают, что модель корректно классифицирует около 90 % всех предсказаний по 117 признакам в совокупности. Заметно более низкое значение $F1_{\text{macro}}$ объясняется наличием в выборке нескольких признаков с экстремально малым числом положительных примеров (10 из 117 признаков имеют менее десяти положительных примеров в обучающей выборке), для которых надёжная классификация минорного класса принципиально невозможна без увеличения объёма данных.

Архитектурные особенности разработанного решения — двухпоточковая модель, объединяющая визуальные признаки изображения и геометрические метаданные bounding box; отдельные проекционные головы для признаков различной сложности обучения; стратегия взвешенных потерь и взвешенного сэмплирования для обработки дисбаланса классов; собственный алгоритм локализации фигуры на основе классических методов обработки изображений — обеспечивают качество классификации, достаточное для практического применения системы.

Для практического использования разработанные модули объединены в микросервисный веб-сервис, развёртываемый через Docker Compose. Архитектура включает шесть сервисов (предобработка, извлечение признаков, инференс, интерпретация, формирование отчёта, API-шлюз), базу данных PostgreSQL и объектное хранилище MinIO. Веб-интерфейс позволяет загрузить рисунок и получить психологический портрет за 2–3 секунды на CPU без необходимости установки локального окружения.

Программный комплекс автоматизирует рутинную часть обработки рисуночных тестов и позволяет психологу сосредоточиться на тех рисунках, которые требуют детального индивидуального анализа. Это особенно ценно при работе с большими коллекциями рисунков (групповое тестирование в детских садах, школах, исследовательские проекты).

Возможные направления развития работы включают:

- расширение датасета редкими классами через целевой сбор рисунков с конкретными признаками, что повысит качество классификации редко встречающихся категорий;
- обучение отдельных специализированных моделей для самых сложных признаков по принципу per-criterion fine-tuning поверх общего бэкбона;
- применение более крупных архитектур и техник self-supervised

- предобучения на расширенной коллекции неразмеченных рисунков;
- расширение комплекса на другие рисуночные тесты (тесты «Дом-Дерево-Человек», «Несуществующее животное», «Моя семья»).

Исходный код разработанного программного комплекса размещён в открытом репозитории. QR-код для быстрого перехода к репозиторию приведён в приложении А на рисунке А.1.

Полученный программный комплекс представляет собой цельное решение, в основе которого лежат современные методы глубокого обучения, классические алгоритмы обработки изображений, корректная инженерная работа с реальным несбалансированным датасетом и интеграция доменных психологических знаний. Результаты работы могут быть использованы как основа для дальнейших исследований и практических применений автоматизированной психологической диагностики на основе рисуночных тестов.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Венгер А. Л. Психологические рисуночные тесты: иллюстрированное руководство. — Москва : ВЛАДОС-ПРЕСС, 2003. — С. 160. — ISBN 5-305-00045-7.
2. Krizhevsky A., Sutskever I., Hinton G. E. ImageNet Classification with Deep Convolutional Neural Networks // Advances in Neural Information Processing Systems. Т. 25. — Curran Associates, Inc., 2012. — С. 1097—1105. — URL: <https://papers.nips.cc/paper/4824-imagenet-classification-with-deep-convolutional-neural-networks>.
3. Deep Residual Learning for Image Recognition / К. Хе [и др.] // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). — 2016. — С. 770—778. — DOI: 10.1109/CVPR.2016.90.
4. Integration Definition for Function Modeling (IDEF0) : тех. отч. / National Institute of Standards ; Technology. — Gaithersburg, MD, 1993. — FIPS PUB 183.
5. Sechidis K., Tsoumakas G., Vlahavas I. On the Stratification of Multi-Label Data // Machine Learning and Knowledge Discovery in Databases. Т. 6913. — Springer, 2011. — С. 145—158. — (Lecture Notes in Computer Science). — DOI: 10.1007/978-3-642-23808-6_10.
6. Bradski G. The OpenCV Library // Dr. Dobb's Journal of Software Tools. — 2000. — URL: <https://opencv.org/> (дата обращения 30.04.2026).
7. Ioffe S., Szegedy C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift // Proceedings of the 32nd International Conference on Machine Learning (ICML). — 2015. — С. 448—456. — URL: <http://proceedings.mlr.press/v37/ioffe15.html> (дата обращения 30.04.2026).
8. Dropout: A Simple Way to Prevent Neural Networks from Overfitting / N. Srivastava [и др.] // Journal of Machine Learning Research. — 2014. — Т. 15, № 56. — С. 1929—1958. — URL: <http://jmlr.org/papers/v15/srivastava14a.html> (дата обращения 30.04.2026).
9. Multi-Task Learning for Dense Prediction Tasks: A Survey / S. Vandenhende [и др.] // IEEE Transactions on Pattern Analysis and Machine Intelligence. — 2022. — Т. 44, № 7. — С. 3614—3633. — DOI: 10.1109/TPAMI.2021.3054719.

10. Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification / К. Хе [и др.] // Proceedings of the IEEE International Conference on Computer Vision (ICCV). — 2015. — С. 1026—1034. — DOI: 10.1109/ICCV.2015.123.
11. Focal Loss for Dense Object Detection / T.-Y. Lin [и др.] // Proceedings of the IEEE International Conference on Computer Vision (ICCV). — 2017. — С. 2980—2988. — DOI: 10.1109/ICCV.2017.324.
12. Loshchilov I., Hutter F. Decoupled Weight Decay Regularization // International Conference on Learning Representations (ICLR). — 2019. — URL: <https://openreview.net/forum?id=Bkg6RiCqY7> (дата обращения 30.04.2026).
13. Kingma D. P., Ba J. Adam: A Method for Stochastic Optimization // International Conference on Learning Representations (ICLR). — 2015. — URL: <https://arxiv.org/abs/1412.6980> (дата обращения 30.04.2026).
14. Loshchilov I., Hutter F. SGDR: Stochastic Gradient Descent with Warm Restarts // International Conference on Learning Representations (ICLR). — 2017. — URL: <https://openreview.net/forum?id=Skq89Scxx> (дата обращения 30.04.2026).
15. Ramírez S. FastAPI — Modern, fast, web framework for building APIs with Python. — 2024. — URL: <https://fastapi.tiangolo.com/> (дата обращения 23.04.2026).
16. Christie T. Uvicorn — The lightning-fast ASGI server for Python. — 2024. — URL: <https://www.uvicorn.org/> (дата обращения 25.04.2026).
17. PyTorch: An Imperative Style, High-Performance Deep Learning Library / A. Paszke [и др.] // Advances in Neural Information Processing Systems. Т. 32. — 2019. — С. 8024—8035. — URL: <https://papers.nips.cc/paper/9015-pytorch-an-imperative-style-high-performance-deep-learning-library>.
18. Jocher G., Chaurasia A., Qiu J. Ultralytics YOLOv8. — 2023. — URL: <https://github.com/ultralytics/ultralytics> (дата обращения 23.04.2026).
19. PostgreSQL Global Development Group. PostgreSQL: The World's Most Advanced Open Source Relational Database. — 2024. — URL: <https://www.postgresql.org/> (дата обращения 23.04.2026).
20. MinIO, Inc. MinIO — High Performance Object Storage compatible with Amazon S3. — 2024. — URL: <https://min.io/> (дата обращения 28.04.2026).

21. Docker, Inc. Docker — Develop, ship, and run applications. — 2024. — URL: <https://www.docker.com/> (дата обращения 23.04.2026).

22. Sasaki Y. The Truth of the F-measure // Teach Tutor Mater. — 2007. — URL: <https://www.cs.odu.edu/~mukka/cs795sum09dm/Lecturenotes/Day3/F-measure-YS-26Oct07.pdf> (дата обращения 30.04.2026).

ПРИЛОЖЕНИЕ А

Исходный код

QR-код на репозиторий с исходным кодом разработанного комплекса приведён на рисунке А.1.



Рисунок А.1 - QR-код на репозиторий с исходным кодом

ПРИЛОЖЕНИЕ Б

Архитектура нейросетевой модели




Рисунок Б.1 - Архитектура нейросетевой модели