



МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(национальный исследовательский университет)»

Институт (Филиал) № 8 «Компьютерные науки и прикладная математика» Кафедра 806

Группа М8О-408Б-22 Направление подготовки 01.03.02 «Прикладная математика и информатика»

Профиль Информатика

Квалификация: бакалавр

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА БАКАЛАВРА

На тему: Распознавание визуальных признаков детских рисунков, ассоциированных с психологическими характеристиками ребёнка, нейросетевыми методами

Автор ВКРБ: Шелаев Серафим Ильич ()

Руководитель: Судаков Владимир Анатольевич ()

Консультант: — ()

Консультант: — ()

Рецензент: — ()

К защите допустить

Заведующий кафедрой № 806 Крылов Сергей Сергеевич ()

____ мая 2026 года

РЕФЕРАТ

Выпускная квалификационная работа бакалавра состоит из 41 страницы, 10 рисунков, 2 таблиц, 15 использованных источников, 2 приложений.

ДЕТСКИЕ РИСУНКИ, ПСИХОЛОГИЧЕСКАЯ ДИАГНОСТИКА, КЛАССИФИКАЦИЯ ИЗОБРАЖЕНИЙ, СВЁРТОЧНЫЕ НЕЙРОННЫЕ СЕТИ, MULTI-TASK LEARNING, ОБРАБОТКА ИЗОБРАЖЕНИЙ, КОМПЬЮТЕРНОЕ ЗРЕНИЕ, ТЕСТ ВЕНГЕРА, ПСИХОЛОГИЧЕСКИЙ ПОРТРЕТ

Объектом разработки в данной работе является программный комплекс автоматического анализа детских рисунков человека для оценки психологических характеристик ребёнка.

Цель работы — разработать нейросетевую систему распознавания визуальных признаков детских рисунков и их сопоставления с психологическими чертами на основе методики А. Л. Венгера.

Основное содержание работы состояло в проектировании собственной двухпоточной свёрточной нейронной сети, разработке алгоритма предобработки изображений на основе классических операций обработки изображений, обучении модели на 117 признаках в режиме multi-task и реализации модуля генерации текстового психологического портрета.

Основным результатом работы является программный комплекс на языке Python с использованием библиотек PyTorch и OpenCV.

Данные результаты разработки предназначены для использования специалистами в области детской психологии в качестве вспомогательного инструмента предварительного анализа, а также в исследовательских целях для анализа больших объёмов рисуночных тестов.

Внедрение разработки позволяет автоматизировать рутинную часть обработки рисуночных тестов, что снижает нагрузку на специалиста и повышает воспроизводимость результатов.

СОДЕРЖАНИЕ

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ	4
ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ	5
ВВЕДЕНИЕ	6
1 ПРЕДМЕТНАЯ ОБЛАСТЬ И ПОСТАНОВКА ЗАДАЧИ	8
1.1 Рисуночные тесты как инструмент психологической диагностики	8
1.2 Список психологических черт и канонические признаки рисунка	9
1.3 Современные подходы к классификации изображений	9
1.4 Особенности задачи и подход к её решению	10
1.5 Постановка задачи	11
2 РАЗРАБОТКА ПРОГРАММНОГО КОМПЛЕКСА	13
2.1 Общая архитектура решения	13
2.2 Описание датасета и его подготовка	14
2.3 Модуль предобработки изображений	16
2.4 Архитектура нейросети	19
2.5 Функции потерь и стратегия обучения	21
2.6 Словарь интерпретаций признаков	24
2.7 Генератор текстового психологического портрета	26
3 ЭКСПЕРИМЕНТАЛЬНОЕ ИССЛЕДОВАНИЕ	28
3.1 Условия проведения экспериментов	28
3.2 Метрики качества	28
3.3 Результаты на тестовой выборке	29
3.4 Анализ распределения метрик по признакам	29
3.5 Демонстрация работы программного комплекса	30
3.6 Анализ временных характеристик	32
3.7 Сфера применения и ограничения	33
ЗАКЛЮЧЕНИЕ	35
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	38
ПРИЛОЖЕНИЕ А Исходный код	40
ПРИЛОЖЕНИЕ Б Архитектура нейросетевой модели	41

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

В настоящей выпускной квалификационной работе бакалавра применяют следующие термины с соответствующими определениями:

Рисуночный тест — проективная психодиагностическая методика, основанная на интерпретации создаваемого испытуемым рисунка

Multi-task learning — парадигма обучения, в которой одна модель одновременно решает несколько связанных задач, используя общее представление признаков

F1-мера — гармоническое среднее точности (precision) и полноты (recall) бинарного или мультиклассового классификатора

Ограничивающий прямоугольник — прямоугольная область изображения, в которую заключён обнаруженный объект; описывается координатами левого верхнего и правого нижнего углов

Адаптивная бинаризация — метод бинаризации изображения, в котором порог вычисляется индивидуально для каждой точки на основе локальной окрестности

Морфологические операции — базовые операции обработки бинарных изображений: эрозия, дилатация, замыкание (closing), размыкание (opening), основанные на структурирующем элементе

Выделение связных компонент — метод обработки бинарного изображения, при котором смежные единичные пиксели группируются в связные области; для каждой области вычисляются её координаты, размеры и площадь

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ

В настоящей выпускной квалификационной работе бакалавра применяют следующие сокращения и обозначения:

СНС — свёрточная нейронная сеть

МО — машинное обучение

API — программный интерфейс приложения (англ. Application Programming Interface)

TTA — Test-Time Augmentation — усреднение предсказаний по нескольким аугментированным версиям одного изображения

CLANE — Contrast Limited Adaptive Histogram Equalization — адаптивное локальное выравнивание гистограммы с ограничением контраста

MLP — Multi-Layer Perceptron — многослойный перцептрон

GPU — Graphics Processing Unit — графический процессор

CV — Computer Vision — компьютерное зрение

ВВЕДЕНИЕ

Актуальность темы данной работы связана с растущей нагрузкой на детских психологов в образовательных учреждениях и медицинских центрах. Рисуночные тесты — одна из наиболее распространённых проективных методик, применяемых для предварительного скрининга психологических состояний детей дошкольного и младшего школьного возраста. Среди них особое место занимает тест «Рисунок человека», методология интерпретации которого детально разработана А. Л. Венгером. Однако ручная обработка рисунка специалистом занимает значительное время и подвержена субъективным факторам. Автоматизация хотя бы части этого процесса с помощью методов машинного обучения позволяет масштабировать применение методики и обеспечить воспроизводимость результатов.

Современные свёрточные нейронные сети успешно применяются для широкого спектра задач классификации изображений. Однако специфика детских рисунков — бледные карандашные штрихи, схематичность, разнообразие стилей, разная плотность заполнения листа — ставит ряд особых задач: точная локализация фигуры на странице, обработка изображений с низким контрастом, корректное распознавание сильно несбалансированных категорий признаков.

Помимо технической задачи распознавания признаков, существует не менее важная задача доменной интерпретации: нейросеть выдаёт техническую характеристику рисунка (например, «размер крупный», «нажим сильный», «отсутствует шея»), но конечному пользователю необходимо получить психологически осмысленный текст, обобщающий совокупность признаков в характеристику ребёнка.

Цель работы — разработать нейросетевую систему распознавания визуальных признаков детских рисунков и их сопоставления с психологическими чертами на основе методики А. Л. Венгера. Для достижения поставленной цели в работе были решены следующие задачи:

- проведён анализ предметной области рисуночных тестов и существующих подходов к автоматизации их интерпретации;
- разработан алгоритм предобработки изображений, реализующий локализацию фигуры человека на листе на основе классических операций обработки изображений;

- спроектирована и обучена собственная нейронная сеть для одновременной классификации признаков рисунка;
- составлен словарь интерпретаций, сопоставляющий технические признаки рисунка с каноническими психологическими чертами по А. Л. Венгеру;
- реализован модуль генерации текстового психологического портрета на основе предсказаний модели;
- проведено экспериментальное исследование качества модели на тестовой выборке.

Для разработки системы необходимо изучить инструменты и методы, решающие поставленные задачи. Работа основывается на следующих библиотеках, технологиях и алгоритмах:

- Python является основным языком программирования, применяемым при разработке;
- PyTorch обеспечивает построение, обучение и применение нейронных сетей;
- OpenCV применяется для реализации алгоритма локализации фигуры на изображении;
- scikit-learn обеспечивает разбиение датасета и расчёт метрик качества;
- iterative-stratification используется для группового стратифицированного разбиения мультиметочных данных;
- Pillow выполняет загрузку, преобразование и сохранение изображений;
- Google Colab Notebooks предоставляет вычислительную платформу с графическим ускорителем для обучения модели.

В результате выполнения работы был разработан программный комплекс на языке Python, состоящий из модуля препроцессинга, обученной нейросетевой модели, словаря интерпретаций признаков и генератора текстового психологического портрета.

Результаты работы могут быть использованы психологами и педагогами в образовательных и медицинских учреждениях для предварительного анализа, а также в научных исследованиях для автоматизированной обработки больших объемов детских рисунков.

1 ПРЕДМЕТНАЯ ОБЛАСТЬ И ПОСТАНОВКА ЗАДАЧИ

1.1 Рисуночные тесты как инструмент психологической диагностики

Рисуночные тесты относятся к классу проективных психодиагностических методик. Их основная идея заключается в том, что в свободном изобразительном продукте отражаются устойчивые личностные особенности, эмоциональные состояния и социальные установки автора рисунка [1]. Среди множества методик особое место занимает тест «Рисунок человека», восходящий к работам К. Махвер [2]: ребёнку предлагается нарисовать человека на чистом листе бумаги, после чего психолог анализирует получившееся изображение по большому числу формальных и содержательных критериев.

Методология интерпретации, разработанная А. Л. Венгером, описана в книге «Психологические рисуночные тесты: иллюстрированное руководство» [1] и применяется на практике российскими специалистами. В рамках этой методологии каждый рисунок описывается по более чем сотне критериев, которые объединены в смысловые блоки: «расположение на листе», «размер рисунка», «нажим», «тело», «ноги», «одежда» и другие. Для каждого блока определены наблюдаемые варианты либо бинарные индикаторы.

Каждой комбинации значений сопоставляется набор гипотетических психологических интерпретаций. Например, очень крупный рисунок ассоциирован с демонстративностью или импульсивностью, очень мелкий — с тревожностью. Множество таких сопоставлений образует доменное знание методики.

Существенно, что одна и та же черта обычно поддерживается несколькими признаками рисунка одновременно. Поэтому при интерпретации психолог не выносит заключения по одиночному признаку, а строит общую картину, учитывая количество подтверждающих признаков (поддержку черты).

1.2 Список психологических черт и канонические признаки рисунка

В настоящей работе использован экспертно составленный список из 26 канонических психологических черт, включающий, в частности: тревожность личностную, состояние тревоги, демонстративность, агрессивность и ряд других. Каждая черта снабжена кратким текстовым описанием, поясняющим её клиническое содержание.

Список из 117 наблюдаемых признаков рисунка предоставлен научным руководителем. Признаки разделены на две группы по типу:

- бинарные — индикаторы наличия или отсутствия конкретного элемента;
- категориальные — мультиклассовые описания, для каждого из которых задан исчерпывающий список вариантов.

1.3 Современные подходы к классификации изображений

Задача распознавания признаков на изображении сводится к задаче классификации. Для каждого бинарного признака требуется обучить классификатор с двумя классами, для каждого категориального — мультиклассовый классификатор. С учётом совместного множества признаков задача относится к классу multi-label / multi-task classification.

Современным стандартом решения подобных задач являются свёрточные нейронные сети. Их прорыв в задачах классификации изображений принято связывать с работой по обучению глубокой свёрточной сети AlexNet на наборе ImageNet [3], после которой свёрточные архитектуры стали доминирующим инструментом распознавания визуальных образов. Ключевым архитектурным элементом сетей семейства ResNet [4] являются остаточные соединения (skip connections), которые передают активации через несколько слоёв напрямую, обходя промежуточные блоки. Это решает проблему затухающих градиентов в очень глубоких сетях и позволяет обучать сети с числом слоёв от десятков до сотен.

Для multi-task обучения распространён подход с общим бэкбоном (одной сетью, извлекающей признаки из изображения) и отдельными классификационными головами для каждой задачи. Совместное обучение позволяет частично разделять пространство признаков между задачами и

сокращать требуемый объём данных по сравнению с обучением отдельной модели на каждую задачу. Однако такой подход уязвим к ситуациям конкуренции градиентов, когда одна задача начинает доминировать в обучении и подавляет остальные. Для смягчения этого эффекта применяются взвешивание функции потерь, перевешивание сэмплов и стратификация выборки.

Существенной особенностью задач классификации признаков рисунка является сильный дисбаланс классов: ряд бинарных признаков имеет менее одного процента положительных примеров в общей выборке. Прямое применение перекрёстной энтропии на таких данных приводит к тому, что модель обучается предсказывать мажоритарный класс, не учитывая редкие. Для исправления этой проблемы в литературе предложен ряд техник: повторная выборка минорного класса, недо-выборка мажоритарного, взвешивание потерь по обратной частоте классов.

1.4 Особенности задачи и подход к её решению

Особенностью детских рисунков являются: малый контраст линий относительно фона, разнообразие стилей и плотности изображения, размещение фигуры в произвольной области листа, наличие посторонних деталей (фона, подписи, одежды). Эти особенности требуют дополнительного этапа предобработки: локализации фигуры на странице и извлечения её ограничивающего прямоугольника.

Для задачи локализации фигуры на изображении в работе разработан собственный алгоритм на основе классических операций обработки изображений (адаптивная бинаризация, морфологические операции, выделение связных компонент). В отличие от готовых детекторов объектов на основе машинного обучения, такой алгоритм лишён зависимости от внешних предобученных моделей и может быть полностью описан и обоснован в рамках работы.

Важно также отметить, что после кропа фигуры и приведения её к фиксированному квадратному размеру теряется информация о масштабе и положении фигуры на исходном листе, которая может быть существенна для ряда признаков рисуночного теста (например, для признака «размер рисунка», определяющегося отношением площади фигуры к площади листа). Для сохранения этой информации в работе используется двухпоточная

архитектура: помимо самого изображения, в модель подаётся дополнительный вектор геометрических метаданных bounding box. Подробное описание архитектуры приводится в Главе 2.

1.5 Постановка задачи

В рамках данной работы решается следующая задача. Дан датасет из 8179 изображений детских рисунков формата png/jpeg, сопровождаемый таблицей разметки в формате CSV. Каждой записи сопоставлены значения 117 признаков, предоставленные экспертами-психологами по методологии А. Л. Венгера.

Для обучения и валидации нейросетевой модели используется набор изображений детских рисунков, полученный из образовательных учреждений (школ и детских садов) следующих регионов Российской Федерации: Самарская область, Республика Чувашия, Московская область, Вологодская область. База данных изображений и разметка предоставлены Московским государственным психолого-педагогическим университетом. Разметка выполнена специалистами в области детской психологии и отражает визуальные признаки, ассоциированные с психологическими характеристиками детей.

Требуется:

- разработать алгоритм предобработки изображений, обеспечивающий извлечение фигуры с произвольного листа;
- спроектировать и обучить нейросетевую модель, классифицирующую все 117 признаков по входному рисунку;
- обеспечить корректную обработку дисбаланса классов и сильной разнородности количеств положительных примеров между признаками;
- составить словарь сопоставления признаков с 26 каноническими психологическими чертами и реализовать на его основе модуль генерации текстового психологического портрета;
- провести экспериментальное исследование качества модели на тестовой выборке.

Целевые показатели качества по тестовой выборке — F1-мера (micro), F1-мера (weighted) и F1-мера (macro). Все три варианта усреднения F1-меры приводятся параллельно, поскольку каждый из них характеризует качество модели по своему: F1-мера (micro) и F1-мера (weighted) отражают долю

верных предсказаний на типичных рисунках, тогда как F1-мера (macro) показывает качество распознавания всех классов одновременно, в том числе минорных.

2 РАЗРАБОТКА ПРОГРАММНОГО КОМПЛЕКСА

2.1 Общая архитектура решения

Разработанная система представляет собой программный комплекс анализа детских рисунков, функционально декомпозированный на пять последовательных модулей в нотации IDEF0. Каждый из модулей решает свою подзадачу и передаёт результат следующему этапу обработки. Структура декомпозиции приведена на рисунке 1.




Рисунок 1 Функциональная декомпозиция программного комплекса анализа детских рисунков

Назначение каждого из модулей следующее:

- A1. Приём и предобработка изображений — принимает на вход исходный отсканированный рисунок и подготавливает его для нейросетевой модели. Включает три подэтапа: чтение и

декодирование файла (A1.1), локализацию фигуры на листе на основе классических методов обработки изображений (A1.2), а также кроп и ресайз выделенной области до стандартного размера 384×384 (A1.3).

- A2. Извлечение признаков — формирует входы для нейросетевой модели: визуальные признаки кропа через свёрточный бэкбон (A2.1) и вектор bbox-метаданных из 12 геометрических характеристик расположения фигуры на исходном листе (A2.2).
- A3. Классификация признаков — ядро системы. Загружает веса обученной нейросетевой модели из реестра (A3.1), выполняет двухпоточный (two-stream) инференс на изображении и bbox-метаданных (A3.2) и формирует на выходе 117 предсказаний по экспертно разработанной системе признаков рисунка (A3.3).
- A4. Интерпретация результатов — транслирует предсказания модели в психологические термины. Использует словарь интерпретаций, построенный на основе методики А. Л. Венгера (A4.1), и подсчитывает поддержку для каждой из 26 канонических психологических черт по всем активным предсказаниям модели (A4.2).
- A5. Формирование отчёта — формирует итоговый текстовый результат для пользователя. Ранжирует психологические черты по числу поддерживающих их признаков (A5.1) и собирает на их основе связный текстовый психологический портрет с пояснениями и подтверждающими признаками (A5.2).

В целом архитектура построена по принципу последовательной обработки: на вход подаётся изображение детского рисунка, на выходе формируется текстовый психологический портрет. Каждый модуль имеет чётко определённые входы и выходы, что обеспечивает прозрачность работы системы и возможность независимой замены отдельных компонентов (например, замены модели классификации более сложной архитектурой без необходимости переработки модулей предобработки и интерпретации).

2.2 Описание датасета и его подготовка

В работе использован датасет из 8179 отсканированных детских рисунков, полученный из образовательных учреждений (школ и детских

садов) Самарской области, Республики Чувашии, Московской области и Вологодской области. База изображений и разметка предоставлены Московским государственным психолого-педагогическим университетом. Разметка выполнена специалистами в области детской психологии. Имена файлов изображений включают идентификатор, состоящий из условного кода учреждения и сведений о возрасте и поле ребёнка.

Сопровождающая разметка содержит записи в CSV-таблице, каждая запись соответствует одному рисунку и содержит значения 117 экспертно проставленных признаков, а также служебные поля (код рисунка, возраст и пол ребёнка).

Установлено, что в разметке встречаются дубликаты по полю «Код рисунка»: для 61 уникального кода имеется от двух до десяти записей с возможными расхождениями в значениях признаков. Это объясняется независимой разметкой одного и того же рисунка несколькими экспертами. Для устранения противоречий применяется голосование большинством (majority vote) по каждому признаку независимо: для бинарного признака значение «1» устанавливается, если не менее половины копий пометили признак как присутствующий; для категориального — выбирается наиболее частое непустое значение, в случае равенства частот — первое встреченное непустое значение.

После дедупликации каждому уникальному коду соответствует одна запись с консолидированной разметкой. Записи, для которых не найдено соответствующее изображение в каталоге картинок (по нормализованному имени файла), исключаются. В результате получается выборка из 7000+ примеров, готовая для обучения модели.

Для разбиения на обучающую, валидационную и тестовую части применяется групповое стратифицированное разбиение в пропорции 70/15/15 с использованием библиотеки `iterative-stratification` [5]. Стратификация производится по бинарным индикаторам редких классов наиболее сложных для распознавания признаков. Так как после дедупликации каждый код встречается ровно один раз, разбиение автоматически становится `group-safe`: код не может одновременно попасть в обучающую и тестовую части.

2.3 Модуль предобработки изображений

Модуль предобработки реализует локализацию фигуры человека на отсканированном листе и формирует на её основе кропированное квадратное изображение фиксированного размера и вектор из 12 геометрических метаданных. Алгоритм собран из классических операций обработки изображений библиотеки OpenCV [6] без использования предобученных нейронных моделей детекции, что обеспечивает прозрачность и воспроизводимость поведения модуля. С точки зрения зависимостей алгоритм может рассматриваться как реализованный с нуля: используются только базовые примитивы (бинаризация, морфологические операции, выделение связных компонент), а вся прикладная логика обработки — последовательность шагов, фильтрация компонент по критериям, объединение — спроектирована в рамках настоящей работы.

Исходное изображение приводится к одноканальному виду. Из соображений устойчивости к артефактам сканера и неровностям краёв исходного листа от каждой стороны изображения отрезается полоса шириной 3 % от соответствующего размера. Этот отступ позволяет исключить из дальнейшей обработки тени, царапины и линии разлиновки, попадающие в зону края.

К внутренней области изображения применяется адаптивная бинаризация с гауссовым ядром. Размер локального окна — 31×31 пиксель, поправка к локальному среднему — 5 единиц яркости. Адаптивная бинаризация выбрана вместо глобальной, поскольку исходные сканы могут иметь неравномерную яркость (например, более тёмные углы листа), и глобальный порог даёт некачественный результат.

К результату бинаризации применяется медианный фильтр с ядром 3×3 . Этот этап удаляет одиночные ложные точки, возникающие при бинаризации из-за зернистости бумаги и шумов сканера, не влияя при этом на сплошные штрихи рисунка.

К отфильтрованному изображению применяется морфологическая операция замыкания (closing) с эллиптическим структурирующим элементом радиусом 13×13 пикселей (функция `cv2.morphologyEx` с операцией `MORPH_CLOSE`). Замыкание заполняет небольшие разрывы между близко расположенными штрихами, что позволяет объединить разделённые части

одной фигуры (например, отдельные штрихи, образующие очертания тела) в одну связную область. Эллиптический структурирующий элемент выбран для нейтрального поведения по обеим осям; его размер (13×13) подобран эмпирически как компромисс между склейкой штрихов одной фигуры и исключением случайной склейки фигуры с посторонними объектами.

К результату морфологической обработки применяется алгоритм выделения связных компонент с расчётом статистик (функция `cv2.connectedComponentsWithStats`). На выходе — список областей с указанием для каждой её ограничивающего прямоугольника, площади (количество единичных пикселей) и центра масс. Эти статистики используются на следующем этапе для отбора компонент, относящихся к фигуре.

Каждая обнаруженная связная компонента проходит проверку по четырём независимым критериям. Компонента отбрасывается, если выполняется хотя бы одно из условий:

- площадь её ограничивающего прямоугольника составляет менее 0,05 % от площади всего изображения (компонента слишком мала, скорее всего — остаточный шум);
- ограничивающий прямоугольник занимает более 92 % по обоим измерениям (компонента занимает почти весь лист, скорее всего — рамка сканера или искусственная граница);
- отношение большей стороны ограничивающего прямоугольника к меньшей превышает 12 (компонента сильно вытянутая, скорее всего — линия края листа или складка бумаги);
- плотность заполнения единичных пикселей внутри ограничивающего прямоугольника составляет менее 0,5 % (компонента слишком разреженная, скорее всего — остаточные точки шума, а не связный объект).

Компоненты, прошедшие фильтрацию, образуют список кандидатов на принадлежность фигуре.

Из списка кандидатов выбирается компонента с наибольшей площадью ограничивающего прямоугольника. Она используется в качестве *якорной* (anchor) — предполагается, что эта компонента принадлежит наиболее заметной части фигуры (туловище или большой контур). Затем к якорной компоненте присоединяются все остальные кандидаты, чьи центры масс

отстоят от центра якоря не более чем на расстояние

$$D = \max(3 \cdot s_{anchor}, 0.12 \cdot \max(W, H)),$$

где s_{anchor} — больший из размеров якоря, W и H — размеры внутренней области изображения. Эта формула адаптивно выбирает радиус объединения: если якорная компонента маленькая (например, голова), то радиус ограничен трёхкратным её размером; если большая, — то всегда не менее 12 % от размеров изображения. Такой подход обеспечивает корректное извлечение цельной фигуры даже когда отдельные её части (голова, тело, конечности) фрагментированы тонкими линиями и не образуют одну связную область после морфологической обработки.

Результирующий ограничивающий прямоугольник представляет собой объединение ограничивающих прямоугольников всех присоединённых компонент.

Полученный ограничивающий прямоугольник расширяется на 8 % по каждой стороне для запаса (на случай, если контур фигуры был обрезан слишком плотно). По расширенным координатам выполняется обрезка исходного изображения. Если результат не является квадратом, выполняется дополнение белым фоном до квадрата по большей стороне (фигура центрируется в квадрате). Затем результат приводится к фиксированному разрешению 384×384 пикселя билинейной интерполяцией.

Для каждого изображения помимо самого кропа вычисляется вектор из 12 геометрических метаданных, описывающих положение и размер найденной фигуры на исходном листе. Эти признаки используются как второй вход нейронной сети (см. подраздел 2.4).

- относительная ширина и высота bounding box (доли от размеров листа);
- относительная площадь bounding box;
- относительные координаты центра bounding box по горизонтали и вертикали;
- отношение высота к ширине;
- четыре бинарных индикатора касания краёв листа;
- нормализованное расстояние от центра bounding box до ближайшего угла листа;

- индикатор источника детекции.

Эти метаданные позволяют модели использовать абсолютную информацию о размере и положении фигуры на странице, которая в значительной мере утрачивается после кропа и масштабирования изображения.

2.4 Архитектура нейросети

Для классификации 117 признаков спроектирована собственная двухпоточковая (two-stream) свёрточная нейронная сеть, обучаемая с нуля на целевой выборке детских рисунков. Общая схема архитектуры приведена в приложении на рисунке Б.1.

Первый поток обрабатывает кропированное изображение размером 320×320 пикселей. Сеть состоит из пяти основных этапов:

- Stem — первый свёрточный слой с ядром 7×7 , нормализацией активаций по батчу (BatchNorm) [7], ReLU и максимальным пулингом 3×3 со страйдом 2. Большое начальное ядро мотивировано особенностью детских рисунков: типичные карандашные штрихи длинные, и одно ядро 7×7 захватывает целые сегменты, в отличие от стандартных ядер 3×3 ;
- Stage 2 (64 канала) — два residual-блока с последующим max-pool;
- Stage 3 (128 каналов) — два residual-блока с последующим max-pool;
- Stage 4 (256 каналов) — два residual-блока с последующим max-pool, выход используется как первый источник многомасштабных признаков;
- Stage 5 (384 канала) — один residual-блок, выход используется как второй источник многомасштабных признаков.

Каждый residual-блок реализует стандартную схему: две последовательные свёртки 3×3 с BatchNorm и ReLU, и пропускающее соединение. При несовпадении числа каналов или страйда в skip-соединение добавляется проекционная свёртка 1×1 . Использование residual-связей обеспечивает устойчивое распространение градиентов в глубокой сети и облегчает оптимизацию.

С целью повышения детализации признакового представления используется конкатенация выходов четвёртого и пятого этапов, пропущенных через адаптивный усредняющий пулинг до размера 1×1 :

$$\mathbf{f}_{img} = [\text{pool}(\text{stage}_4(x)) ; \text{pool}(\text{stage}_5(x))] \in \mathbb{R}^{640} \quad (1)$$

Применение конкатенации признаков с двух уровней обусловлено следующими соображениями. Признаки stage 4 (256 каналов) содержат среднеуровневые геометрические паттерны (формы, очертания, локальные особенности), полезные для распознавания мелких деталей рисунка (форма глаз, наличие пуговиц, штриховка). Признаки stage 5 (384 канала) содержат высокоуровневые семантические признаки, релевантные для общих характеристик (поза фигуры, ракурс, размер). Совместное использование обоих уровней даёт богатое признаковое представление, способное обслуживать как мелкозернистые, так и крупнозернистые задачи распознавания.

Второй поток обрабатывает 12-мерный вектор геометрических метаданных. Перед подачей в сеть метаданные нормируются по среднему и стандартному отклонению, вычисленным на обучающей выборке. Преобразование выполняет двухслойный MLP с активациями ReLU и одним слоем дропаута [8]:

$$\mathbf{f}_{bbox} = \text{MLP}(\mathbf{x}_{bbox}) \in \mathbb{R}^{32} \quad (2)$$

Векторы признаков от двух потоков конкатенируются и пропускаются через одну из двух параллельных проекционных голов. Признаки, для которых ожидается повышенная сложность распознавания, направляются через выделенную проекцию; остальные — через общую проекцию. Такое разделение является разновидностью многозадачного обучения с группировкой задач [9]: оно уменьшает конкуренцию градиентов между задачами разной сложности и обеспечивает более устойчивое обучение признаков с малым числом примеров. Каждая проекция сужает признаковое пространство до 256 нейронов с дропаутом 0,3.

Финальный слой состоит из 117 параллельных классификационных голов: каждая голова — один линейный слой, отображающий 256-мерный признак в логиты соответствующего числа классов (2 для бинарного признака, K для категориального с K классами).

Общее число параметров модели составляет около 5,5 миллионов.

Размер сохранённого чекпоинта — около 22 МБ. Инициализация всех свёрточных и линейных слоёв выполнена методом Кайминга [10], что соответствует выбранной активации ReLU и обеспечивает корректное масштабирование начальных активаций по слоям.

Фрагмент реализации архитектуры на PyTorch приведен на рисунке 2 ниже.

```
1 class ResidualBlock(nn.Module):
2     def __init__(self, in_ch, out_ch, stride=1):
3         super().__init__()
4         self.conv1 = nn.Conv2d(in_ch, out_ch, 3,
5                                 stride=stride, padding=1, bias=False)
6         self.bn1 = nn.BatchNorm2d(out_ch)
7         self.conv2 = nn.Conv2d(out_ch, out_ch, 3, padding=1, bias=
8                                 False)
9         self.bn2 = nn.BatchNorm2d(out_ch)
10        if stride != 1 or in_ch != out_ch:
11            self.shortcut = nn.Sequential(
12                nn.Conv2d(in_ch, out_ch, 1, stride=stride, bias=
13                           False),
14                nn.BatchNorm2d(out_ch))
15        else:
16            self.shortcut = nn.Identity()
17    def forward(self, x):
18        out = F.relu(self.bn1(self.conv1(x)), inplace=True)
19        out = self.bn2(self.conv2(out))
20        out = out + self.shortcut(x)
21        return F.relu(out, inplace=True)
```

Рисунок 2 Фрагмент кода реализации обучения

2.5 Функции потерь и стратегия обучения

Функция потерь для одного признака зависит от его типа. Для бинарного признака используется взвешенная перекрёстная энтропия с весами классов $\alpha = (1.0, \min(\sqrt{N_-/N_+}, 10))$, где N_- и N_+ — количества отрицательных и положительных примеров в обучающей выборке. Корень из отношения и ограничение значением 10 защищают градиент от взрыва при экстремальном дисбалансе. В качестве альтернативы рассматривалось применение фокальной функции потерь (focal loss) [11], специально

предложенной для задач с сильным дисбалансом классов; однако сочетание корневого взвешивания и `WeightedRandomSampler` даёт сопоставимое поведение при существенно меньшем числе гиперпараметров для подбора.

Для категориального признака используется взвешенная перекрёстная энтропия с label smoothing 0.05 и весами $\alpha_i = \min(\sqrt{N_{max}/N_i}, 5)$, где N_i — количество примеров класса i , N_{max} — наибольшее из N_i . Класс «пусто» рассматривается как полноценный класс «признак не проявлен» и обучается наравне с остальными.

Совокупная функция потерь — среднее по 117 признакам:

$$\mathcal{L} = \frac{1}{117} \sum_{i=1}^{117} \mathcal{L}_i(\mathbf{f}_{proj}, y_i) \quad (3)$$

Для смягчения проблемы дисбаланса дополнительно применяется `WeightedRandomSampler`, то есть каждому примеру обучающей выборки присваивается вес, повышенный относительно базового для тех примеров, которые имеют положительные метки редких классов. Веса ограничены диапазоном $[1, 2.5]$. Сэмплирование выполняется с возвращением, что обеспечивает многократное предъявление редких примеров за эпоху без необходимости их физического дублирования.

Реализация цикла обучения приведена ниже на рисунке 3.

```

1 opt = torch.optim.AdamW(model.parameters(),
2                           lr=1e-4, weight_decay=5e-4)
3
4 for epoch in range(50):
5     lr_mult = cosine_warmup(epoch, total=50, warmup=3)
6     for pg in opt.param_groups:
7         pg['lr'] = pg['_base_lr'] * lr_mult
8
9     model.train()
10    for imgs, bboxes, labels in train_loader:
11        imgs, bboxes = imgs.to(device), bboxes.to(device)
12        opt.zero_grad()
13        logits = model(imgs, bboxes)
14        total = 0.0
15        for name in criteria:
16            tg = labels[name].to(device)
17            total = total + loss_fns[name](logits[safe[name]], tg)
18        loss = total / len(criteria)
19        loss.backward()
20        torch.nn.utils.clip_grad_norm_(model.parameters(), 1.0)
21        opt.step()
22
23    f1 = validate(model, val_loader)
24    if f1 > best_f1:
25        torch.save(model.state_dict(), 'best.pth')
26        best_f1 = f1

```

Рисунок 3 Фрагмент кода реализации цикла обучения

К каждому изображению на этапе обучения применяется набор случайных преобразований, направленный на расширение эффективного разнообразия выборки и повышение устойчивости модели к мелким вариациям рисунка. Применяются: *random affine* с углом поворота до $\pm 6^\circ$ и сдвигом до 5 % по каждой оси (имитация наклона при сканировании и неточного выравнивания листа), *random crop* из увеличенного на 32 пикселя изображения до целевого размера 320×320 для имитации неполной центровки фигуры, *color jitter* с амплитудами яркости и контраста до 15 % для имитации различий в условиях сканирования и качестве оригинала, *random erasing* с вероятностью 0,2. Намеренно не используется горизонтальное

отражение: ряд признаков рисунка содержит указание на правую и левую стороны, и зеркальное отражение нарушает их семантику.

При валидации и инференсе аугментации не применяются, выполняется только `resize` до целевого размера и нормализация по среднему и стандартному отклонению.

Применяется оптимизатор AdamW [12] (модификация оптимизатора Adam [13] с разделённым `decoupled weight decay`) с базовой скоростью обучения 10^{-4} , `weight decay` $5 \cdot 10^{-4}$, обрезкой нормы градиента до 1,0. Размер пакета равен 32 примерам.

Расписание скорости обучения — косинусное затухание с разогревом в течение трёх эпох [14]. На фазе разогрева скорость обучения линейно растёт от нуля до базовой; затем плавно снижается по косинусоиде до нуля к концу обучения. Это обеспечивает мягкий старт и постепенное затухание шагов оптимизации, что эмпирически даёт более устойчивое поведение модели и лучшие финальные значения метрик по сравнению с фиксированной или ступенчато-снижающейся скоростью.

Поскольку модель обучается с нуля, технику «заморозка-разморозка» применять не требуется: все параметры модели обучаются совместно с самого начала. Это упрощает процедуру обучения и устраняет необходимость дополнительных переключений в графике оптимизации.

При обучении смешанная точность намеренно отключена в пользу одинарной точности. Это связано с тем, что при обучении с нуля и сильных весовых коэффициентах функции потерь начальные градиенты могут принимать большие значения; в режиме `fp16` это иногда приводит к численным переполнениям и пропуску шагов оптимизатора, что наблюдалось в предварительных экспериментах. Использование стандартной одинарной точности — `fp32`, обеспечивает устойчивость обучения за счёт большего времени на одну эпоху.

Полное число эпох — 50, ранняя остановка по отсутствию улучшения F1-меры на валидационной выборке в течение 8 эпох с минимумом в 25 эпох до проверки условия. Сохранение лучшего чекпоинта производится по значению F1-меры на валидационной выборке после каждой эпохи.

2.6 Словарь интерпретаций признаков

Связь между техническими признаками рисунка и психологическими

чертами реализована через JSON-словарь интерпретаций `criteria_interpretations.json` объёмом около 60 КБ. Структура словаря включает три блока:

- раздел `traits` — 26 канонических черт с текстовыми описаниями;
- раздел `criteria` — 117 признаков, каждый снабжён указанием типа (`binary_presence` или `multiclass_value`), категории и раздела книги-первоисточника, набора связанных черт. Для бинарных признаков — общий список, а для категориальных — словарь, в котором каждому конкретному значению класса противопоставлен свой список черт;
- раздел `meta` — сведения о версии словаря и источниках.

Содержательное наполнение словаря построено на основе книги А. Л. Венгера [1]. Для каждого признака изучен соответствующий раздел методики, после чего составлен набор связанных черт. Особое внимание уделено категориальным признакам: для них один и тот же признак в разных классах ассоциирован с принципиально разными чертами.

Один признак рисунка может одновременно являться индикатором нескольких черт, и одна черта обычно поддерживается набором различных признаков. Поэтому при использовании словаря в составе генератора портрета, каждой черте сопоставляется счётчик поддержки, равный количеству предсказанных моделью признаков, ассоциированных с данной чертой. Это позволяет ранжировать черты в итоговом тексте по степени их выраженности в рисунке. В таблице 1 приведена часть канонических черт с краткими пояснениями; полный перечень из 26 черт содержится в JSON-словаре интерпретаций.

Таблица 1 Часть канонических психологических черт

Черта	Краткое пояснение
Тревожность личностная	Устойчивая склонность к беспокойству, сниженная самооценка
Состояние тревоги	Ситуативная тревога, проявленная в момент рисования
Демонстративность	Стремление быть в центре внимания, экспансивное поведение
Агрессивность	Склонность к враждебному, конкурентному поведению

2.7 Генератор текстового психологического портрета

Модуль генерации портрета принимает на вход словарь предсказаний модели $\{c_i \mapsto v_i\}_{i=1}^{117}$ и словарь интерпретаций. Для каждого признака с положительным предсказанием ($v_i \neq 0$, $v_i \neq$ пусто) извлекается соответствующий список черт, и для каждой черты t инкрементируется счётчик поддержки:

$$S(t) = \sum_{i=1}^{117} \mathbb{I}[t \in \text{traits}(c_i, v_i)] \quad (4)$$

Параллельно для каждой черты накапливается список свидетельств — пар «признак, значение», давших вклад в её поддержку. Это позволяет в итоговом тексте указать, какие именно особенности рисунка обусловили вывод о наличии черты.

Финальный текст портрета содержит следующие разделы: заголовок и краткое пояснение, перечень из 7 наиболее устойчиво проявленных черт с порогом поддержки не менее 2 признаков, для каждой черты — описание из словаря и до 4 конкретных подтверждающих свидетельств; раздел менее устойчивых тенденций (с поддержкой 1 признака) и итоговое замечание о вероятностном характере выводов. Объём типового портрета — 25–40 строк.

Реализация модуля выполнена на чистом Python без внешних зависимостей и может применяться как в офлайн-режиме, так и в составе интерактивных систем. Фрагмент кода функции вычисления поддержки черт приведён ниже на рисунке 4.

```

1 from collections import Counter, defaultdict
2
3 def compute_trait_support(predictions, criteria_dict):
4     support = Counter()
5     evidence = defaultdict(list)
6     for crit_name, value in predictions.items():
7         if value in (0, '', None):
8             continue
9         entry = criteria_dict['criteria'].get(crit_name)
10        if not entry:
11            continue
12        if entry['kind'] == 'binary_presence':
13            traits = entry.get('traits', [])
14        else:
15            traits = entry.get('class_traits', {}).get(value, [])
16        for t in traits:
17            support[t] += 1
18            evidence[t].append((crit_name, value))
19    return support, evidence

```

Рисунок 4 Фрагмент кода для генерации психологического портрета

3 ЭКСПЕРИМЕНТАЛЬНОЕ ИССЛЕДОВАНИЕ

3.1 Условия проведения экспериментов

Все эксперименты проводились в облачной среде Google Colab Notebooks с использованием графического ускорителя NVIDIA Tesla T4, 16 ГБ видеопамати. Программное окружение: Python 3.10, PyTorch 2.x с поддержкой CUDA, библиотеки torchvision, opencv-python, pandas, scikit-learn, iterative-stratification.

Размер пакета при обучении — 32 примера, размер изображения — 320×320 пикселей, число эпох — 70 с ранней остановкой. Время обучения одной эпохи составляет около 60 секунд, полный цикл обучения занимает около 100 минут.

Воспроизводимость обеспечивается фиксированным значением `random_state = 42` для всех источников случайности: разбиения выборки, инициализации весов сети, перемешивания данных и взвешенного сэмплирования.

3.2 Метрики качества

Для оценки качества модели применяются три варианта F1-меры [15]:

- $F1_{\text{micro}}$ — F1, вычисленная по агрегированной матрице ошибок с одинаковым весом каждого предсказания. В целом, можно сказать близка к ассигасу и отражает общую долю правильных предсказаний;
- $F1_{\text{weighted}}$ — среднее F1 по классам с весами, пропорциональными количеству примеров каждого класса в выборке. Учитывает редкость классов, не штрафует избыточно за их пропуск;
- $F1_{\text{macro}}$ — среднее значение F1 по классам каждого признака с равными весами для всех классов независимо от их частоты.

Чувствительна к качеству модели на минорных классах.

Каждая из трёх метрик имеет своё практическое значение. $F1_{\text{micro}}$ и $F1_{\text{weighted}}$ отражают качество системы на типичных рисунках — то, как часто модель будет давать корректное предсказание для произвольно выбранного образца. $F1_{\text{macro}}$ показывает, насколько хорошо модель справляется со всеми классами одновременно, в том числе с теми, которые встречаются редко. В

работе все три метрики приводятся параллельно, без выбора одной из них в качестве главной.

В качестве итоговых показателей по всем 117 признакам используются средние значения F1 каждого вида, рассчитанные как среднее арифметическое по 117 признакам.

3.3 Результаты на тестовой выборке

Результаты, полученные разработанной моделью на тестовой выборке, которая составляет около 1000 рисунков, приведены в таблице 2.

Таблица 2 Метрики качества на тестовой выборке

Метрика	Значение
$F1_{\text{micro}}$	0,901
$F1_{\text{weighted}}$	0,873
$F1_{\text{macro}}$	0,554

Значение $F1_{\text{micro}} = 0,901$ означает, что модель корректно классифицирует около 90 % всех предсказаний по 117 признакам в совокупности. Близкое к нему значение $F1_{\text{weighted}} = 0,873$ подтверждает устойчивость качества при учёте различной частоты классов. Отличия между двумя метриками невелики, что указывает на отсутствие систематического перекоса в сторону какой-либо группы классов.

Заметно более низкое значение $F1_{\text{macro}} = 0,554$ объясняется особенностями выборки и формулы метрики. $F1_{\text{macro}}$ штрафует модель за каждый минорный класс, который она не научилась распознавать, причём с равным весом независимо от размера класса. В рассматриваемом датасете 10 из 117 признаков имеют менее десяти положительных примеров в обучающей выборке. Для таких признаков модель в большинстве случаев предсказывает мажоритарный класс, что обеспечивает высокую общую точность, но низкую F1-меру по минорному классу. Эти 10 признаков существенно опускают среднее значение $F1_{\text{macro}}$, не влияя при этом на $F1_{\text{micro}}$ и $F1_{\text{weighted}}$.

3.4 Анализ распределения метрик по признакам

Распределение значений $F1_{\text{weighted}}$ по 117 признакам приведено на

рисунке 5.




Рисунок 5 Распределение $F1_{\text{weighted}}$ по 117 признакам: по горизонтальной оси — значение метрики (шаг бина 0,05), по вертикальной — количество признаков в бине.

Подавляющее большинство признаков имеет значение $F1_{\text{weighted}}$ в диапазоне 0,85–0,99, что подтверждает однородно высокое качество модели по совокупности задач.

Среди 117 признаков особо выделяются 10 признаков с экстремально малым числом положительных примеров (менее 10 в обучающей выборке). Для них объём данных принципиально не позволяет обучить классификатор, надёжно распознающий минорный класс: модель в большинстве случаев предсказывает мажоритарный класс, что обеспечивает высокое значение $F1_{\text{weighted}}$ (близкое к 1) и низкое значение $F1_{\text{macro}}$ (около 0,5). Эти признаки оказывают значительное влияние на среднее значение $F1_{\text{macro}}$ по всей выборке, но практически не влияют на $F1_{\text{micro}}$ и $F1_{\text{weighted}}$.

В целом распределение метрик показывает, что модель успешно справляется с задачей классификации признаков рисунка для типичных рисунков. Снижение $F1_{\text{macro}}$ обусловлено редкими признаками, для которых при имеющемся объёме обучающих данных надёжная классификация минорного класса принципиально невозможна.

3.5 Демонстрация работы программного комплекса

Для демонстрации работы конвейера выберем рисунок из тестовой выборки и пропустим его через всю цепочку обработки. Результат работы

модуля предобработки (исходный лист и локализованная фигура) приведён на рисунке 6.



Рисунок 6 Пример работы модуля предобработки: слева — исходный отсканированный лист, справа — результат локализации и кропа фигуры до квадрата 384 × 384.

После прохождения через нейросетевую модель формируется набор из 117 предсказаний. Активные предсказания (бинарные, равные единице, либо категориальные с непустым значением) для рассматриваемого рисунка приведены на рисунке 7.

ТОП-10 АКТИВНЫХ ПРЕДСКАЗАНИЙ МОДЕЛИ:	
детализированность	→ 'Средняя (стандарт)/3,'
зубы	→ 'Отсутствуют/1'
изображение в рамке	→ 'нет/2'
изображение персонажа	→ 'нет/2'
нажим без особенностей/1	→ 1
одежда отсутствует, тело изображено условно/4	→ 1
особенности линии "промахивающиеся"/6	→ 1
особенности линии без особенностей/1	→ 1
персонаж	→ 'нет/2'
поза	→ 'Стоит/1'

Рисунок 7 Пример активных предсказаний для одного рисунка

Эти предсказания транслируются через словарь интерпретаций в счётчики поддержки психологических черт. Фрагмент сгенерированного на их основе психологического портрета приведён на рисунке 8.

КЛЮЧЕВЫЕ ОСОБЕННОСТИ:

1. Негативизм (поддержка: 2 признак(ов))
 - негативистические установки, оппозиция, протест.Поддерживается: «одежда | отсутствует, тело изображено условно/4»; «тело | прямоугольное/3»
2. Признаки отклонения от нормы (поддержка: 2 признак(ов))
 - признаки органических, психических или развивающих нарушений.Поддерживается: «одежда | отсутствует, тело изображено условно/4»; «особенности линии | "промахивающиеся"/6»
3. Возбужденное состояние (поддержка: 2 признак(ов))
 - общее возбуждение, расторможенность, повышенная активность.Поддерживается: «особенности линии | "промахивающиеся"/6»; «фигура в движении» = нет/2

Менее устойчивые тенденции (≥ 1 признак, требуют осторожности):

- Интроверсия (поддержка: 1)
- Контроль (поддержка: 1)
- Импульсивность (поддержка: 1)
- Творческая направленность (поддержка: 1)

Рисунок 8 Фрагмент сгенерированного психологического портрета

Полный портрет включает дополнительный раздел менее устойчивых тенденций (с поддержкой 1 признака) и итоговое замечание о вероятностном характере выводов и необходимости индивидуальной беседы для постановки окончательной оценки. Время генерации портрета (от подачи изображения на вход системы до текстового результата) составляет около 1 секунды на одном GPU.

3.6 Анализ временных характеристик

Измерены характеристики времени работы программного комплекса в инференс-режиме на NVIDIA Tesla T4. Обработка одного рисунка от подачи на вход сырого изображения до возврата итогового текстового портрета занимает в среднем около 0,4 секунды. Это время разбивается на следующие компоненты:

- чтение и декодирование изображения из файла — около 0,05 с;
- локализация фигуры (адаптивная бинаризация, морфология, выделение связных компонент, фильтрация и объединение) — около 0,15 с;
- кроп, паддинг, ресайз — менее 0,01 с;
- инференс — около 0,18 с (один прямой проход на одном изображении);
- декодирование 117 предсказаний и применение словаря

интерпретаций — менее 0,01 с;

- ранжирование черт и формирование итогового текста — менее 0,01 с.

При пакетной обработке (batch inference) среднее время на один рисунок снижается за счёт лучшего использования параллелизма GPU: при обработке пакета из 32 рисунков время на одно изображение составляет около 0,05 секунд.

Время обучения модели от начала до завершения — порядка 50 минут на одном NVIDIA Tesla T4 (50 эпох с ранней остановкой). Размер сохранённого чекпоинта — около 22 МБ. Эти характеристики делают разработанный комплекс полностью применимым в практических условиях: при наличии современного GPU психолог может обработать пакет из сотен рисунков за несколько минут. Малый размер модели также позволяет рассматривать варианты её развёртывания на устройствах с ограниченными вычислительными ресурсами.

3.7 Сфера применения и ограничения

Разработанный программный комплекс может применяться психологами, педагогами и исследователями детской психологии в следующих сценариях.

Первый — предварительный скрининг в детских садах и школах. Психолог может пропустить пакет рисунков через систему за минуты вместо часов и получить ранжированный список рисунков, требующих более детального индивидуального анализа.

Второй — исследовательские задачи, в которых требуется обработка больших коллекций рисуночных тестов. Например, выявление средних тенденций в группе по полу или возрасту, корреляций психологических характеристик с социальными факторами, динамики изменения психологических черт со временем.

Третий — учебные курсы по практической психологической диагностике. Система может применяться для демонстрации связи признаков рисунка с психологическими интерпретациями.

Среди ограничений разработки следует отметить следующие:

- а) Система предназначена исключительно для теста «Рисунок человека» и не может быть напрямую применена к другим рисуночным тестам («Дом-Дерево-Человек», «Несуществующее животное», «Моя семья» и др.) без переобучения. Возможна

адаптация архитектуры для других тестов при наличии аналогичной обучающей выборки.

- б) Выводы системы носят гипотетический характер и не могут заменить непосредственное общение специалиста с ребёнком, сбор анамнеза и наблюдение за ребёнком в естественных условиях. Психологический портрет, сгенерированный системой, является лишь предварительной гипотезой и должен подтверждаться независимыми источниками.
- в) Точность предсказаний для редко встречающихся признаков объективно ограничена объёмом обучающих данных и требует осторожной интерпретации. Если итоговый портрет содержит черту, поддерживаемую только одним признаком, имеет смысл отнестись к ней с осторожностью; черты, поддерживаемые тремя и более признаками, существенно более надёжны.
- г) Система обучена на рисунках детей дошкольного и младшего школьного возраста (приблизительно 5–12 лет). Для рисунков существенно других возрастных групп (подростков и взрослых) качество предсказаний может оказаться ниже, поскольку их рисуночные продукты имеют другие стилистические особенности.
- д) Применение системы требует наличия отсканированного или сфотографированного рисунка достаточного качества. Сильно повреждённые, размытые или с фрагментированной фигурой изображения могут давать неустойчивые предсказания.

Указанные ограничения не препятствуют практическому применению системы при учёте описанных условий и интерпретации её выводов как вспомогательных, а не окончательных.

ЗАКЛЮЧЕНИЕ

В результате выполнения выпускной квалификационной работы бакалавра был разработан программный комплекс автоматического распознавания визуальных признаков детских рисунков и сопоставления их с психологическими характеристиками ребёнка нейросетевыми методами. Были решены следующие задачи:

- проведён анализ предметной области рисуночных тестов и существующих подходов к автоматизации их интерпретации;
- разработан собственный алгоритм предобработки изображений, реализующий локализацию фигуры человека на листе на основе классических операций обработки изображений (адаптивная бинаризация, морфологические операции замыкания, выделение связанных компонент, фильтрация и объединение по якорной стратегии);
- спроектирована и обучена двухпоточная собственная свёрточная нейросетевая модель (около 5,5 млн параметров) для одновременной классификации 117 признаков рисунка;
- реализована стратегия обучения, устойчивая к сильному дисбалансу классов: взвешенная перекрёстная энтропия с насыщением весов классов, label smoothing для категориальных признаков, взвешенное случайное сэмплирование, групповое стратифицированное разбиение выборки;
- составлен словарь сопоставления 117 технических признаков с 26 каноническими психологическими чертами на основе методики А. Л. Венгера;
- реализован модуль генерации текстового психологического портрета с ранжированием черт по числу подтверждающих признаков;
- проведено экспериментальное исследование качества модели на тестовой выборке.

На тестовой выборке разработанная система достигла следующих показателей качества: $F1_{\text{micro}} = 0,901$, $F1_{\text{weighted}} = 0,873$, $F1_{\text{macro}} = 0,554$. Значения $F1_{\text{micro}}$ и $F1_{\text{weighted}}$ означают, что модель корректно классифицирует около 90 % всех предсказаний по 117 признакам в совокупности. Заметно более низкое значение $F1_{\text{macro}}$ объясняется наличием в выборке нескольких

признаков с экстремально малым числом положительных примеров (10 из 117 признаков имеют менее десяти положительных примеров в обучающей выборке), для которых надёжная классификация минорного класса принципиально невозможна без увеличения объёма данных.

Архитектурные особенности разработанного решения — двухпоточковая модель, объединяющая визуальные признаки изображения и геометрические метаданные bounding box; отдельные проекционные головы для признаков различной сложности обучения; стратегия взвешенных потерь и взвешенного сэмплирования для обработки дисбаланса классов; собственный алгоритм локализации фигуры на основе классических методов обработки изображений — обеспечивают качество классификации, достаточное для практического применения системы.

Программный комплекс автоматизирует рутинную часть обработки рисуночных тестов и позволяет психологу сосредоточиться на тех рисунках, которые требуют детального индивидуального анализа. Это особенно ценно при работе с большими коллекциями рисунков (групповое тестирование в детских садах, школах, исследовательские проекты).

Возможные направления развития работы включают:

- расширение датасета редкими классами через целевой сбор рисунков с конкретными признаками, что повысит качество классификации редко встречающихся категорий;
- обучение отдельных специализированных моделей для самых сложных признаков по принципу per-criterion fine-tuning поверх общего бэкбона;
- применение более крупных архитектур и техник self-supervised предобучения на расширенной коллекции неразмеченных рисунков;
- расширение комплекса на другие рисуночные тесты (тесты «Дом-Дерево-Человек», «Несуществующее животное», «Моя семья»);
- разработка веб-интерфейса для практической эксплуатации системы психологами без технической подготовки.

Исходный код разработанного программного комплекса вместе с обученными весами нейросетевой модели и словарём интерпретаций размещён в открытом репозитории. QR-код для быстрого перехода к репозиторию приведён в приложении А на рисунке А.1, а перечень основных

компонентов комплекса (модулей предобработки, обучения, инференса и генерации портрета, словаря интерпретаций и описания зависимостей среды) приведён в том же приложении непосредственно после рисунка.

Полученный программный комплекс представляет собой цельное end-to-end решение, в основе которого лежат современные методы глубокого обучения, классические алгоритмы обработки изображений, корректная инженерная работа с реальным несбалансированным датасетом и интеграция доменных психологических знаний. Результаты работы могут быть использованы как основа для дальнейших исследований и практических применений автоматизированной психологической диагностики на основе рисуночных тестов.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Венгер А. Л. Психологические рисуночные тесты: иллюстрированное руководство. — Москва : ВЛАДОС-ПРЕСС, 2003. — С. 160. — ISBN 5-305-00045-7.
2. Маховер К. Проективный рисунок человека. — Москва : Смысл, 2009. — С. 158. — ISBN 978-5-89357-265-7.
3. Krizhevsky A., Sutskever I., Hinton G. E. ImageNet Classification with Deep Convolutional Neural Networks // Advances in Neural Information Processing Systems. T. 25. — Curran Associates, Inc., 2012. — С. 1097—1105. — URL: <https://papers.nips.cc/paper/4824-imageNet-classification-with-deep-convolutional-neural-networks>.
4. Deep Residual Learning for Image Recognition / К. Хе [и др.] // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). — 2016. — С. 770—778. — DOI: 10.1109/CVPR.2016.90.
5. Sechidis K., Tsoumakas G., Vlahavas I. On the Stratification of Multi-Label Data // Machine Learning and Knowledge Discovery in Databases. T. 6913. — Springer, 2011. — С. 145—158. — (Lecture Notes in Computer Science). — DOI: 10.1007/978-3-642-23808-6_10.
6. Bradski G. The OpenCV Library // Dr. Dobb's Journal of Software Tools. — 2000. — URL: <https://opencv.org/> (дата обращения 30.04.2026).
7. Ioffe S., Szegedy C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift // Proceedings of the 32nd International Conference on Machine Learning (ICML). — 2015. — С. 448—456. — URL: <http://proceedings.mlr.press/v37/ioffe15.html> (дата обращения 30.04.2026).
8. Dropout: A Simple Way to Prevent Neural Networks from Overfitting / N. Srivastava [и др.] // Journal of Machine Learning Research. — 2014. — Т. 15, № 56. — С. 1929—1958. — URL: <http://jmlr.org/papers/v15/srivastava14a.html> (дата обращения 30.04.2026).
9. Multi-Task Learning for Dense Prediction Tasks: A Survey / S. Vandenhende [и др.] // IEEE Transactions on Pattern Analysis and Machine Intelligence. — 2022. — Т. 44, № 7. — С. 3614—3633. — DOI: 10.1109/TPAMI.2021.3054719.

10. Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification / К. Хе [и др.] // Proceedings of the IEEE International Conference on Computer Vision (ICCV). — 2015. — С. 1026—1034. — DOI: 10.1109/ICCV.2015.123.
11. Focal Loss for Dense Object Detection / T.-Y. Lin [и др.] // Proceedings of the IEEE International Conference on Computer Vision (ICCV). — 2017. — С. 2980—2988. — DOI: 10.1109/ICCV.2017.324.
12. Loshchilov I., Hutter F. Decoupled Weight Decay Regularization // International Conference on Learning Representations (ICLR). — 2019. — URL: <https://openreview.net/forum?id=Bkg6RiCqY7> (дата обращения 30.04.2026).
13. Kingma D. P., Ba J. Adam: A Method for Stochastic Optimization // International Conference on Learning Representations (ICLR). — 2015. — URL: <https://arxiv.org/abs/1412.6980> (дата обращения 30.04.2026).
14. Loshchilov I., Hutter F. SGDR: Stochastic Gradient Descent with Warm Restarts // International Conference on Learning Representations (ICLR). — 2017. — URL: <https://openreview.net/forum?id=Skq89Scxx> (дата обращения 30.04.2026).
15. Sasaki Y. The Truth of the F-measure // Teach Tutor Mater. — 2007. — URL: <https://www.cs.odu.edu/~mukka/cs795sum09dm/Lecturenotes/Day3/F-measure-YS-26Oct07.pdf> (дата обращения 30.04.2026).

ПРИЛОЖЕНИЕ А

Исходный код

QR-код на репозиторий с исходным кодом разработанного комплекса приведён на рисунке А.1.



Рисунок А.1 QR-код на репозиторий с исходным кодом

ПРИЛОЖЕНИЕ Б

Архитектура нейросетевой модели




Рисунок Б.1 Архитектура нейросетевой модели